

第三章 无约束非线性规划

§ 3.1 最优性条件

本章主要研究如下优化模型：

$$\min_{x \in R_n} f(x)$$

其中, $f: R^n \rightarrow R$, 且 f 具有二阶连续偏导数。

全局最优解：对于多元函数 $f(x)$, 若点 $x^* \in R^n$, $\forall x \in R^n$, 均有 $f(x^*) \leq f(x)$, 则 x^* 为全局最优解。

局部最优解：对于多元函数 $f(x)$, 若点 x^* 存在一邻域 $\delta(x^*)$, 使得 $\forall x \in \delta(x^*)$, 均有 $f(x^*) \leq f(x)$, 则 x^* 为 $f(x)$ 的局部极小点。

§ 3.1 最优性条件

多元函数的一阶导数——梯度

对于函数 $f(x)$, $x \in R^n$, 若在点 x_0 处自变量 $x=(x_1, \dots, x_n)^T$ 的各分量的偏导数 $\partial f(x_0) / \partial x_i (i=1, \dots, n)$ 都存在, 则称 $f(x)$ 在点 x_0 处一阶可导, 并称向量

$$\nabla f(x_0) = \left(\frac{\partial f(x_0)}{\partial x_1}, \dots, \frac{\partial f(x_0)}{\partial x_n} \right)^T$$

是 $f(x)$ 在点 x_0 处的梯度或一阶导数。

§ 3.1 最优性条件

多元函数的二阶导数

对于函数 $f(x)$, $x \in R^n$, 若在点 x_0 处自变量 $x=(x_1, \dots, x_n)^T$ 的各分量的二阶偏导数 $\partial^2 f(x_0) / \partial x_i \partial x_j (i, j = 1, \dots, n)$ 都存在, 则称 $f(x)$ 在点 x_0 处二阶可导, 并称矩阵

$$\nabla^2 f(x_0) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial x_1^2} & \dots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x)}{\partial x_2 \partial x_1} & \dots & \frac{\partial^2 f(x)}{\partial x_2 \partial x_n} \\ \dots & \dots & \dots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \dots & \frac{\partial^2 f(x)}{\partial x_n^2} \end{bmatrix}$$

是 $f(x)$ 在点 x_0 处的二阶导数或黑塞矩阵。

§ 3.1 最优性条件

泰勒展开

对于一元函数 $f(x)$ ，若在点 x_0 处 n 阶可导，其泰勒展开为

$$f(x) \approx f(x_0) + f'(x_0)(x - x_0) + \frac{1}{2!}f''(x_0)(x - x_0)^2 + \cdots + \frac{1}{n!}f^{(n)}(x_0)(x - x_0)^n$$

对于多元函数 $f(x)$ ， $x \in R^n$ ，若 $f(x)$ 在点 x_0 具有二阶连续偏导数，则 $f(x)$ 的二阶泰勒展开为

$$f(x) \approx f(x_0) + \nabla f(x_0)^T (x - x_0) + \frac{1}{2} (x - x_0)^T \nabla^2 f(x_0) (x - x_0)$$

§ 3.1 最优性条件

定理1 (局部极小点的一阶必要条件)

设 $f(x)$ 在 x^* 处可微, 若 x^* 为局部极小点, 则必有 $\nabla f(x^*) = 0$.

定理2 (局部极小点的二阶必要条件)

设 $f(x)$ 在 x^* 二阶连续可微, 若 x^* 为局部极小点, 则有 $\nabla f(x^*) = 0$ 和 $\nabla^2 f(x^*) \geq 0$.

§ 3.1 最优性条件

定理3 (局部极小点的二阶充分条件)

设 $f(x)$ 在 x^* 二阶连续可微, 若 $\nabla f(x^*) = 0$ 且 $\nabla^2 f(x^*) > 0$, 则 x^* 是局部极小点。

定理4 (全局极小点的充要条件)

设 $f(x)$ 是定义在 R^n 上的可微凸函数, $x^* \in R^n$, 则 x^* 为全局极小点的充要条件是 $\nabla f(x^*) = 0$.

§ 3.1 最优性条件

例1 求解下列问题的局部极小点

$$\min f(x) = (x_1^2 - 1)^2 + x_1^2 + x_2^2 - 2x_1$$

§ 3.1 最优性条件

例2 利用最优性条件求解下列问题：

$$\min f(x) = \frac{1}{3}x_1^3 + \frac{1}{3}x_2^3 - x_2^2 - x_1$$

先求 $f(x)$ 的一阶偏导数：

$$\frac{\partial f}{\partial x_1} = x_1^2 - 1, \quad \frac{\partial f}{\partial x_2} = x_2^2 - 2x_2$$

$$\text{令 } \nabla f(x) = \begin{bmatrix} x_1^2 - 1 \\ x_2^2 - 2x_2 \end{bmatrix} = 0$$

$$\text{解方程组得, } x^{(1)} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad x^{(2)} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad x^{(3)} = \begin{bmatrix} -1 \\ 0 \end{bmatrix}, \quad x^{(4)} = \begin{bmatrix} -1 \\ 2 \end{bmatrix}$$

§ 3.1 最优性条件

再求 $f(x)$ 的黑塞矩阵:

$$\nabla^2 f(x) = \begin{bmatrix} 2x_1 & 0 \\ 0 & 2x_2 - 2 \end{bmatrix}$$

$$\text{则有 } \nabla^2 f(x^{(1)}) = \begin{bmatrix} 2 & 0 \\ 0 & -2 \end{bmatrix} \quad \nabla^2 f(x^{(2)}) = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

$$\nabla^2 f(x^{(3)}) = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix} \quad \nabla^2 f(x^{(4)}) = \begin{bmatrix} -2 & 0 \\ 0 & 2 \end{bmatrix}$$

因此, $x^{(1)}$, $x^{(4)}$ 不是极值点, $x^{(2)}$ 是局部极小点,
 $x^{(3)}$ 是局部极大点。

§ 3.2 一维搜索

一维搜索---解决单变量函数的极小化问题。


试探法(区间收缩法)：即按某种方式找试探点，通过一系列试探点来确定极小点。

函数逼近法：用某种较简单的曲线逼近/近似代替原来的函数曲线，并利用近似曲线的极小值来估计目标函数的极小值。

这两类方法一般只能求得极小点的近似值。

§ 3.2 一维搜索

(一) 平分法



对于一个区间 $[a, b]$ ，如果 $f'(a) < 0$ ， $f'(b) > 0$ ，则在 $[a, b]$ 之间必有极小点 x^* ，且 $f'(x^*) = 0$ 。

平分法，即按照某一准则，逐步缩小区间长度，并使其始终含有极小点，直到区间足够小，则得到满足误差要求的解。

§ 3.2 一维搜索

取 $x^0 = (a+b)/2$, 若 $f'(x^0) > 0$, 则在 $[a, x^0]$ 中有极小点, 此时, 以 $[a, x^0]$ 作为新的区间;

若 $f'(x^0) < 0$, 则在 $[x^0, b]$ 中有极小点, 因此, 以 $[x^0, b]$ 作为新的区间。

继续这个过程, 直至区间充分小或 $f'(x^0) = 0$.

对于初始区间的确定, 可以先取一个初始点 S_0 , 如果 $f'(S_0) < 0$, 则令 $S_1 = S_0 + \Delta S$, 此时, 若 $f'(S_1) > 0$, 则区间 $[a, b] = [S_0, S_1]$; 否则, 令 $S_2 = S_1 + \Delta S$, 直至 $f'(S_i) > 0$ 出现。

§ 3.2 一维搜索

例：利用平分法求解下列问题：


$$\begin{aligned} \min \quad & x^2 + 2x \\ & -3 \leq x \leq 5 \end{aligned}$$

令 $f(x) = x^2 + 2x$ ，则 $f'(x) = 2x + 2$ 。对于区间 $[a, b] = [-3, 5]$ ，取 $x^0 = (-3 + 5)/2 = 1$ ，有 $f'(x^0) = 4 > 0$ ，则令 $a_1 = -3$ ， $b_1 = 1$ ，取 $x^1 = (-3 + 1)/2 = -1$ ，有 $f'(x^1) = 0$ 。

故 $x^* = x^1 = -1$ 为极小点。

§ 3.2 一维搜索

(二) 0.618法/黄金分割法




基本思想：通过选择两个试探点，使包含极小点的区间不断缩短，当区间长度小到一定程度时，区间上各点的函数值均接近极小值，因此，任一点都可作为极小点的近似。

对于函数 $f(x)$ ，若存在 $x^* \in [a, b]$ ，使 $f(x)$ 在 $[a, x^*]$ 上严格递减，在 $[x^*, b]$ 上严格递增，则称 $f(x)$ 为 $[a, b]$ 上的单峰函数。

在区间内选择两个点，令 $x_1, x_2 \in [a, b]$ ，且 $x_1 < x_2$ ，使 x^* 包含在区间 $[x_1, x_2]$ 内，则有：若 $f(x_1) > f(x_2)$ ，则 $x^* \in [x_1, b]$ ；

若 $f(x_1) \leq f(x_2)$ ，则 $x^* \in [a, x_2]$ 。

§ 3.2 一维搜索



在 k 次迭代后, 有 $x^* \in [a_k, b_k]$, 取 $\lambda_k, \mu_k \in [a_k, b_k]$, 且 $\lambda_k < \mu_k$
若 $f(\lambda_k) \leq f(\mu_k)$, 则令 $a_{k+1} = a_k, b_{k+1} = \mu_k$; 若 $f(\lambda_k) > f(\mu_k)$, 则令
 $a_{k+1} = \lambda_k, b_{k+1} = b_k$, 如此下去。

如何选取 λ_k 和 μ_k 呢?

λ_k 和 μ_k 取在 $[a_k, b_k]$ 中的对称位置;

$$b_k - \lambda_k = \mu_k - a_k$$

每次迭代区间长度缩短比例相同。

$$b_{k+1} - a_{k+1} = \alpha (b_k - a_k)$$

§ 3.2 一维搜索

$$\begin{array}{ccccccc} & & & & b_k - \lambda_k = \mu_k - a_k & & \\ & & & & b_{k+1} - a_{k+1} = \alpha(b_k - a_k) & & \\ & & & & \underbrace{\hspace{10em}} & & \\ a_k & & \lambda_k & & \mu_k & & b_k \end{array}$$

不妨设 $f(\lambda_k) \leq f(\mu_k)$, $a_{k+1} = a_k$, $b_{k+1} = \mu_k$,

整理可得, $\mu_k = a_k + \alpha(b_k - a_k)$ 。

若 $f(\lambda_k) > f(\mu_k)$, $a_{k+1} = \lambda_k$, $b_{k+1} = b_k$, 则 $\lambda_k = a_k + (1-\alpha)(b_k - a_k)$ 。

假设在第 k 次迭代, $f(\lambda_k) \leq f(\mu_k)$, 则 $[a_{k+1}, b_{k+1}] = [a_k, \mu_k]$

在第 $k+1$ 次迭代, $\mu_{k+1} = a_{k+1} + \alpha(b_{k+1} - a_{k+1}) = a_k + \alpha(\mu_k - a_k)$
 $= a_k + \alpha^2(b_k - a_k)$

若令 $\alpha^2 = 1 - \alpha$, 则 $\mu_{k+1} = \lambda_k$, 因此 μ_{k+1} 不必重新计算, 只需求 λ_{k+1} 即可。

解得, $\alpha = \frac{-1 + \sqrt{5}}{2} \approx 0.618$

§ 3.2 一维搜索

0.618法在区间内取点的规则

$$\begin{cases} \mu_k = a_k + 0.618(b_k - a_k) \\ \lambda_k = a_k + 0.382(b_k - a_k) \end{cases}$$

对比平分法与0.618法：

1. 平分法需要求导，因此要求函数可微。
2. 0.618法不需要函数可微，但只适用于单峰函数。

§ 3.2 一维搜索

计算步骤:

1. 设置初始区间 $[a_1, b_1]$, 精度要求 $\varepsilon > 0$, 计算

$$\lambda_1 = a_1 + 0.382(b_1 - a_1), \mu_1 = a_1 + 0.618(b_1 - a_1)$$

$f(\lambda_1)$ 和 $f(\mu_1)$, 令 $k=1$.

2. 若 $b_k - a_k < \varepsilon$, 则停止计算; 否则, 当 $f(\lambda_k) > f(\mu_k)$ 时, 转3;
当 $f(\lambda_k) \leq f(\mu_k)$ 时, 转4.

3. 令 $a_{k+1} = \lambda_k, b_{k+1} = b_k, \lambda_{k+1} = \mu_k, \mu_{k+1} = a_{k+1} + 0.618(b_{k+1} - a_{k+1})$,
计算 $f(\mu_{k+1})$, 转5.

4. 令 $a_{k+1} = a_k, b_{k+1} = \mu_k, \mu_{k+1} = \lambda_k, \lambda_{k+1} = a_{k+1} + 0.382(b_{k+1} - a_{k+1})$,
计算 $f(\lambda_{k+1})$, 转5.

5. 令 $k = k+1$, 返回2.

§ 3.2 一维搜索

例：利用0.618法求解下列问题：

$$\min e^x - 5x$$

$$1 \leq x \leq 2, \varepsilon = 0.04.$$

$$\begin{cases} \mu_k = a_k + 0.618(b_k - a_k) \\ \lambda_k = a_k + 0.382(b_k - a_k) \end{cases}$$

k	a_k	b_k	λ_k	μ_k	$f(\lambda_k)$	$f(\mu_k)$	$b_k - a_k$
1	1	2	1.382	1.618	-2.928	-3.048	1
2	1.382	2	1.618	1.764	-3.048	-2.985	0.618
3	1.382	1.764	1.528	1.618	-3.032	-3.048	0.382
4	1.528	1.764	1.618	1.674	-3.048	-3.037	0.236
5	1.528	1.674	1.584	1.618	-3.046	-3.048	0.146
6	1.584	1.674	1.618	1.640	-3.048	-3.046	0.09
7	1.584	1.640	1.605	1.618	-3.048	-3.048	0.056
8	1.584	1.618					0.036

$$x^* = \frac{1.584 + 1.618}{2} = 1.601$$

§ 3.2 一维搜索

(三) 函数逼近法

基本思想：在迭代点附近用二阶泰勒展开多项式近似目标函数 $f(x)$ ，进而求得极小点的估计值。

设 $f(x)$ 二次可微，在 $f(x)$ 在 x^k 处的二阶泰勒展开式为：

$$f(x) \approx f(x^k) + f'(x^k)(x - x^k) + \frac{1}{2} f''(x^k)(x - x^k)^2$$

令

$$f'(x) = f'(x^k) + f''(x^k)(x - x^k) = 0$$

可得，

$$x^{k+1} = x^k - \frac{f'(x^k)}{f''(x^k)}$$

若 $|f'(x^k)| < \varepsilon$ ，则停止迭代， $x^* = x^k$ 为极小点。

§ 3.2 一维搜索

计算步骤:

1. 给定初始点 x^1 , 精度要求 $\varepsilon > 0$, 令 $k = 1$.
2. 若 $|f'(x^k)| < \varepsilon$, 则停止计算, 得到极小点 x^k ; 否则, 转3.
3. 计算点 x^{k+1} ,

$$x^{k+1} = x^k - \frac{f'(x^k)}{f''(x^k)}$$

令 $k = k+1$, 返回2.

局限性: 对初始点的选择比较敏感。如果初始点靠近极小点, 则可能很快收敛; 如果初始点远离极小点, 迭代产生的点列可能不收敛于极小点。

§ 3.2 一维搜索

$$x^{k+1} = x^k - \frac{f'(x^k)}{f''(x^k)}$$

例：用函数逼近法求解下列问题：

$$\min f(x) = e^x - 5x$$

取 $x^1=2$, $\varepsilon = 0.01$

$$f'(x) = e^x - 5$$

$$f''(x) = e^x$$

k	$x^{(k)}$	$f'(x^{(k)})$	$f''(x^{(k)})$
1	2	2.388	7.388
2	1.677	0.349	5.349
3	1.612	0.012	5.012
4	1.6096	-0.00002	

则 $x^* = x^4 = 1.6096$ 为极小点。

课堂练习

1. 利用0.618法和平分法求解下列问题：

$$\min f(x) = 2x^2 - x - 1$$
$$-1 \leq x \leq 1, \varepsilon = 0.16.$$

k	a_k	b_k	λ_k	μ_k	$f(\lambda_k)$	$f(\mu_k)$	$b_k - a_k$
1	-1	1	-0.236	0.236	-0.653	-1.125	2
2	-0.236	1	0.236	0.528	-1.125	-0.970	1.236
3	-0.236	0.528	0.056	0.236	-1.050	-1.125	0.764
4	0.056	0.528	0.236	0.348	-1.125	-1.106	0.472
5	0.056	0.348	0.168	0.236	-1.112	-1.125	0.292
6	0.168	0.348	0.236	0.279	-1.125	-1.123	0.18
7	0.168	0.279					0.111

$$x^* = \frac{0.168 + 0.279}{2} = 0.2235$$

§ 3.3 最速下降法

迭代法：

给定极小值点的初始估计 x^0 ，利用某种方法找出一系列的点列 $\{x^k\}$ ，使得 $\lim_{k \rightarrow \infty} \|x^k - x^*\| = 0$ 。

怎样产生这个点列呢？

在第 k 次迭代，从 x^k 出发，寻找 x^{k+1} ，而一个向量是由其长度和方向所确定的，即总可以写成

$$x^{k+1} = x^k + \lambda_k d^k$$

其中， d^k 为方向， λ_k 为步长。

各种迭代方法的区别在于确定方向和步长方式的不同，且总是要求所构造出的点列所对应的函数值是单调递减的。

§ 3.3 最速下降法

在 x^k 和 d^k 均已知的情况下, $f(x^k + \lambda d^k)$ 为 λ 的一元函数。

非精确搜索:

存在 λ_k , 使得

$$f(x^{(k)} + \lambda_k d^{(k)}) < f(x^{(k)})$$

精确搜索:

求解以 λ 为变量的一元函数 $f(x^k + \lambda d^k)$ 的极小点, 使得

$$f(x^{(k)} + \lambda_k d^{(k)}) = \min f(x^{(k)} + \lambda d^{(k)})$$


此时, λ_k 为最优步长。

§ 3.3 最速下降法

搜索方向(下降方向):

对于充分小的 $\lambda > 0$, 有 $f(x+\lambda d) < f(x)$, 则 d 为 f 在 x 处的下降方向。

如右图所示, 在 x^k 处有两个运动方向,
为了求极小值, 运动方向应为函数下降的方向。



结论: 函数 $f(x)$ 在点 x^k 的负梯度方向是 x^k 处函数值下降最快的方向, 即 $d^k = -\nabla f(x^k)$.

§ 3.3 最速下降法

搜索方向(下降方向):

任取模为1的方向 d^k 及 $\lambda > 0$, 有 $f(x+\lambda d) < f(x)$, 则 $f(x)$ 在 x^k 处的一阶泰勒展开为

$$f(x) = f(x^k + \lambda d^k) = f(x^k) + \lambda \nabla f^T(x^k) d^k + O(\lambda)$$

$$f(x^k + \lambda d^k) - f(x^k) = \lambda \nabla f^T(x^k) d^k + O(\lambda)$$


$$= \lambda (\nabla f^T(x^k) d^k + \frac{O(\lambda)}{\lambda})$$

↓ λ 充分小

0

$$\nabla f^T(x^k) d^k = \|\nabla f^T(x^k)\| \|d^k\| \cos \theta$$

取 $\cos \theta = -1$, 则 $f(x^k + \lambda d^k) - f(x^k)$ 最小, 即 $\theta = 180^\circ$, $d^k = -\nabla f(x^k)$.



§ 3.3 最速下降法

算法步骤：


1. 选定初始点 x^0 ，给定精度要求 $\varepsilon > 0$ ，令 $k = 0$.
2. 计算搜索方向 $d^k = -\nabla f(x^k)$.
3. 若 $\|d^k\| < \varepsilon$ ，则停止迭代， x^k 为极小点的近似值；否则从 x^k 出发，沿 d^k 方向，求 λ_k ，使 $f(x^k + \lambda_k d^k) = \min f(x^k + \lambda d^k)$.
4. 令 $x^{k+1} = x^k + \lambda_k d^k$ ，且 $k = k+1$ ，返回2.

§ 3.3 最速下降法

相邻两个搜索方向是正交的

利用精确搜索求 $\min \varphi(\lambda) = f(x^k + \lambda d^k)$

令 $\varphi'(\lambda) = 0$, 有 $\nabla f^T(x^k + \lambda_k d^k) d^k = 0$



$$d^k = -\nabla f(x^k)$$

$$(d^{k+1})^T d^k = 0$$

因此，相邻两次迭代搜索方向垂直/正交。

最速下降法可以较快地从初始点到达极小点附近，但在接近极小点时，收敛速度变慢。

§ 3.3 最速下降法

例：求 $\min f(x) = (x_1 - 1)^2 + (x_2 - 1)^2$

取 $x^0 = (0, 0)^T$, $\varepsilon = 0.1$.

解： $\nabla f(x) = (2(x_1 - 1), 2(x_2 - 1))^T$, $d^k = -\nabla f(x^k)$

$k=0$ 时, $d^0 = -(-2, -2)^T = (2, 2)^T$, $\|d^0\| = 2\sqrt{2} > \varepsilon$

从 x^0 出发, 沿 d^0 方向进行搜索, 求步长 λ_1

因 $x^0 + \lambda d^0 = (2\lambda, 2\lambda)^T$ $f(x^0 + \lambda d^0) = (2\lambda - 1)^2 + (2\lambda - 1)^2$

$$\frac{d f(x^0 + \lambda d^0)}{d \lambda} = 4(2\lambda - 1) + 4(2\lambda - 1) = 0$$

可得 $\lambda_0 = 1/2$

令 $x^1 = x^0 + \lambda_0 d^0 = (1, 1)^T$.

$k=1$ 时, $d^1 = (0, 0)^T$, $\|d^1\| = 0 < \varepsilon$

故 $x^* = x^1 = (1, 1)^T$ 为极小点。

§ 3.4 牛顿法和修正牛顿法

牛顿法---一维搜索中函数逼近法的推广

设 $f(x)$ 二次可微, 则 $f(x)$ 在点 x^k 处的二阶泰勒展开为:

$$f(x) \approx \varphi(x) = f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k)$$

令 $\nabla \varphi(x) = \nabla f(x^k) + \nabla^2 f(x^k)(x - x^k) = 0$

当 $\nabla^2 f(x^k)$ 正定, 即 $\nabla^2 f(x^k)^{-1}$ 存在, 则有


$$x^{k+1} = x^k - \nabla^2 f(x^k)^{-1} \nabla f(x^k)$$

令搜索方向为 $d^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$ --- 牛顿方向,

此时, 步长 $\lambda_k = 1$.

§ 3.4 牛顿法和修正牛顿法

$$\varphi(x) = f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k)$$


$$\Gamma(X) = c + b^T X + \frac{1}{2} X^T A X$$

有 $\nabla \Gamma(X) = AX + b, \quad \nabla^2 \Gamma(X) = A$

根据牛顿法的迭代方程，有

$$\begin{aligned} X^1 &= X^0 - \nabla^2 \Gamma(X^0)^{-1} \nabla \Gamma(X^0) \\ &= X^0 - A^{-1} (AX^0 + b) \\ &= -A^{-1} b \quad \longleftarrow \text{二次型的最优解} \end{aligned}$$

说明，牛顿法具有二次终止性。

§ 3.4 牛顿法和修正牛顿法

牛顿法的计算步骤：

1. 给定初始点 x^0 ，精度要求 $\varepsilon > 0$ ，令 $k=0$.
2. 计算 $\nabla f(x^k)$ 和 $\nabla^2 f(x^k)^{-1}$
3. 若 $\|\nabla f(x^k)\| < \varepsilon$ ，则停止迭代；否则令 $d^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$
4. 计算 $x^{k+1} = x^k + d^k$ ，且 $k = k+1$ ，返回2.

对初始点的选择比较敏感，当初始点远离最优解时，算法可能不收敛。

§ 3.4 牛顿法和修正牛顿法

修正牛顿法：

迭代方向--- $d^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$

迭代步长--- 一维搜索求 λ_k

算法步骤：

1. 给定初始点 x^0 ，精度要求 $\varepsilon > 0$ ，令 $k = 0$.

2. 计算 $\nabla f(x^k)$ 和 $\nabla^2 f(x^k)^{-1}$

3. 若 $\|\nabla f(x^k)\| < \varepsilon$ ，则停止迭代；否则令 $d^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$

4. 从 x^k 出发，沿方向 d^k 作一维搜索，计算 λ_k ，使

$$\lambda_k = \arg \min f(x^k + \lambda d^k)$$

5. 令 $x^{k+1} = x^k + \lambda_k d^k$ ，且 $k = k+1$ ，返回2.

§ 3.4 牛顿法和修正牛顿法

修正牛顿法：

迭代方向--- $d^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$

迭代步长--- 一维搜索求 λ_k

优点：二阶收敛，收敛速度快；

迭代点越靠近最优解，收敛速度越快。

局限性：若迭代中目标函数的黑塞矩阵不可逆，则算法无法执行；

黑塞矩阵及其逆的计算量较大。

§ 3.4 牛顿法和修正牛顿法

例1 用牛顿法求解 $\min f(x) = x_1^2 + 25x_2^2$

取 $x^0 = (2, 2)^T$, $\varepsilon = 10^{-6}$.

例2 用修正牛顿法求解 $\min f(x) = x_1 - x_2 + 2x_1^2 + 2x_1x_2 + x_2^2$

取 $x^0 = (0, 0)^T$, $\varepsilon = 10^{-6}$.

§ 3.5 拟牛顿法

在牛顿法中，迭代过程在确定 d^k 时，需要计算 $\nabla^2 f(x^k)^{-1}$ ，计算量较大，且 $\nabla^2 f(x^k)$ 有时也未必可逆，因此，希望用矩阵 H_k 来替代 $\nabla^2 f(x^k)^{-1}$ ，则在迭代过程中搜索方向变为

$$d^k = -H_k \nabla f(x^k)$$

根据Taylor展开，有

$$f(x) \approx f(x^k) + \nabla f(x^k)^T (x - x^k) + \frac{1}{2} (x - x^k)^T \nabla^2 f(x^k) (x - x^k)$$

求 $f(x)$ 的梯度，有 $\nabla f(x) \approx \nabla f(x^k) + \nabla^2 f(x^k)(x - x^k)$

$$\downarrow \quad \text{令 } x = x^{k-1}$$

$$\nabla f(x^{k-1}) \approx \nabla f(x^k) + \nabla^2 f(x^k)(x^{k-1} - x^k)$$

整理得，

$$x^k - x^{k-1} \approx \nabla^2 f(x^k)^{-1} (\nabla f(x^k) - \nabla f(x^{k-1}))$$

§ 3.5 拟牛顿法

$$x^k - x^{k-1} \approx \nabla^2 f(x^k)^{-1} (\nabla f(x^k) - \nabla f(x^{k-1}))$$

令 $\gamma_k = \nabla f(x^k) - \nabla f(x^{k-1})$, $\delta_k = x^k - x^{k-1}$

则有 $H_k \gamma_k = \delta_k \longrightarrow$ 拟牛顿方程

因 $\nabla^2 f(x^k)$ 对称, 所以 H_k 也应是对称的。

如何确定 H_{k+1} ?

令 $H_{k+1} = H_k + \boxed{E_{k+1}} \longleftarrow$ 对称

满足上式中的 E_{k+1} 有很多, 因此拟牛顿算法是一族算法。

变尺度(DFP)算法最为经典/常用。

§ 3.5 拟牛顿法

$$H_k \gamma_k = \delta_k$$

变尺度(DFP)算法

令 $E_{k+1} = \alpha_{k+1} U_{k+1} U_{k+1}^T + \beta_{k+1} V_{k+1} V_{k+1}^T$ ，显然 E_{k+1} 是对称的。

$$\text{则有 } H_{k+1} = H_k + E_{k+1} = H_k + \alpha_{k+1} U_{k+1} U_{k+1}^T + \beta_{k+1} V_{k+1} V_{k+1}^T$$

↓ 两边乘 γ_{k+1}

$$H_{k+1} \gamma_{k+1} = H_k \gamma_{k+1} + \alpha_{k+1} U_{k+1} \boxed{U_{k+1}^T \gamma_{k+1}} + \beta_{k+1} V_{k+1} \boxed{V_{k+1}^T \gamma_{k+1}}$$

$$H_{k+1} \gamma_{k+1} = H_k \gamma_{k+1} + \alpha_{k+1} (U_{k+1}^T \gamma_{k+1}) U_{k+1} + \beta_{k+1} (V_{k+1}^T \gamma_{k+1}) V_{k+1}$$

↓
 δ_{k+1}

为了满足上式，令

$$\begin{aligned} \alpha_{k+1} (U_{k+1}^T \gamma_{k+1}) &= 1 & U_{k+1} &= \delta_{k+1} \\ \beta_{k+1} (V_{k+1}^T \gamma_{k+1}) &= -1 & V_{k+1} &= H_k \gamma_{k+1} \end{aligned}$$

§ 3.5 拟牛顿法

整理得

$$\alpha_{k+1} = \frac{1}{U_{k+1}^T \gamma_{k+1}} = \frac{1}{\delta_{k+1}^T \gamma_{k+1}}$$
$$\beta_{k+1} = -\frac{1}{V_{k+1}^T \gamma_{k+1}} = -\frac{1}{\gamma_{k+1}^T H_k \gamma_{k+1}}$$

则有

$$H_{k+1} = H_k + E_{k+1} = H_k + \frac{\delta_{k+1} \delta_{k+1}^T}{\delta_{k+1}^T \gamma_{k+1}} - \frac{H_k \gamma_{k+1} \gamma_{k+1}^T H_k}{\gamma_{k+1}^T H_k \gamma_{k+1}}$$

$$\gamma_k = \nabla f(x^k) - \nabla f(x^{k-1}), \quad \delta_k = x^k - x^{k-1}$$

§ 3.5 拟牛顿法

DFP算法的计算步骤:

1. 给定初始点 x^0 .
2. 令 $H_0=I$, $k=0$.
3. 若 $\nabla f(x^k)=0$, 则停止迭代; 否则令 $d^k = -H_k \nabla f(x^k)$
4. 从 x^k 出发, 沿方向 d^k 作一维搜索, 计算 λ_k , 令 $x^{k+1} = x^k + \lambda_k d^k$
5. 计算 $\delta_{k+1} = x^{k+1} - x^k$, $\gamma_{k+1} = \nabla f(x^{k+1}) - \nabla f(x^k)$

$$H_{k+1} = H_k + \frac{\delta_{k+1} \delta_{k+1}^T}{\delta_{k+1}^T \gamma_{k+1}} - \frac{H_k \gamma_{k+1} \gamma_{k+1}^T H_k}{\gamma_{k+1}^T H_k \gamma_{k+1}}$$

且 $k = k+1$, 返回3.

§ 3.5 拟牛顿法

例：在DFP方法求解问题的过程中，已知

$$H_k = \begin{pmatrix} 3 & 1 \\ 1 & 1 \end{pmatrix} \quad \gamma_{k+1} = (1, 1)^T, \quad \delta_{k+1} = (1, 2)^T$$

求矩阵 H_{k+1} 。

$$H_{k+1} = H_k + \frac{\delta_{k+1} \delta_{k+1}^T}{\delta_{k+1}^T \gamma_{k+1}} - \frac{H_k \gamma_{k+1} \gamma_{k+1}^T H_k}{\gamma_{k+1}^T H_k \gamma_{k+1}}$$

$$H_{k+1} = \begin{pmatrix} \frac{2}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{5}{3} \end{pmatrix}$$

§ 3.5 拟牛顿法

例：用拟牛顿法求 $\min 2x_1^2 + x_2^2 - 4x_1 + 2$

取 $x^{(0)} = (2, 1)^T, H_0 = I$

解： $\nabla f(x) = (4x_1 - 4, 2x_2)^T$, $\nabla f(x^0) = (4, 2)^T$

因 $\nabla f(x^0) \neq 0$, 令 $d^0 = -H_0 \nabla f(x^0) = (-4, -2)^T$

有 $x^0 + \lambda d^0 = (2 - 4\lambda, 1 - 2\lambda)^T$

$$f(x^0 + \lambda d^0) = 36\lambda^2 - 20\lambda + 3$$

$$\frac{df(x^0 + \lambda d^0)}{d\lambda} = 72\lambda - 20 = 0 \longrightarrow \lambda_0 = 5/18$$

令 $x^1 = x^0 + \lambda_0 d^0 = \left(\frac{8}{9}, \frac{4}{9}\right)^T$, 有 $\nabla f(x^1) = \left(-\frac{4}{9}, \frac{8}{9}\right)^T$

§ 3.5 拟牛顿法

$$\delta_{k+1} = x^{k+1} - x^k, \quad \gamma_{k+1} = \nabla f(x^{k+1}) - \nabla f(x^k)$$

计算 δ_1, γ_1 , 代入 H_{k+1} 的公式, 得有 $H_{k+1} = H_k + \frac{\delta_{k+1} \delta_{k+1}^T}{\delta_{k+1}^T \gamma_{k+1}} - \frac{H_k \gamma_{k+1} \gamma_{k+1}^T H_k}{\gamma_{k+1}^T H_k \gamma_{k+1}}$

$$H_1 = \frac{1}{360} \begin{pmatrix} 86 & -38 \\ -38 & 305 \end{pmatrix}$$

此时, $d^1 = -H_1 \nabla f(x^1) = \frac{12}{51} (1, -4)^T$, 且 $\nabla f(x^1) \neq 0$

根据 $\frac{d f(x^1 + \lambda d^1)}{d \lambda} = 0 \longrightarrow \lambda_1 = 17/36$

令 $x^2 = x^1 + \lambda_1 d^1 = (1, 0)^T$, $\nabla f(x^2) = (0, 0)^T$.

故 $x^* = x^2 = (1, 0)^T$ 为极小点。

§ 3.6 共轭梯度法

定义1 (共轭方向)

设 x, y 是 n 维欧氏空间中两个向量, 即 $x, y \in R^n$, 若有 $x^T y = 0$, 则称 x 与 y 是两个正交的向量。又设 A 是一个 n 阶对称正定矩阵, 若有 $x^T A y = 0$, 则称向量 x 与 y 关于 A 共轭正交, 简称关于 A 共轭。

定义2

设一组非零向量 $p_1, \dots, p_n \in R^n$, A 为 n 阶对称正定阵, 若有下式成立:

$$p_i^T A p_j = 0 \quad (i \neq j, i, j = 1, \dots, n)$$

则称向量组 p_1, \dots, p_n 关于 A 共轭, 也称为 A 的 n 个共轭方向。

特别地, 当 A 为单位阵时, $p_i^T A p_j = p_i^T p_j = 0$, p_i 与 p_j 正交。

§ 3.6 共轭梯度法

性质1

设 A 是 n 阶对称正定阵, p_1, \dots, p_k 是 k 个 A 共轭的非零 n 维向量, 则向量组 p_1, \dots, p_k 必线性无关($k \leq n$)。

性质2

设 p_1, \dots, p_k 是 k 个相互共轭的非零向量, 则有如下结论成立:

$\nabla f(x^{k+1})$ 与 p_1, \dots, p_k 的任意线性组合正交, $1 \leq k < n$.

§ 3.6 共轭梯度法

证明：向量 $(1, 0)^T$ 和 $(3, -2)^T$ 关于矩阵

$$A = \begin{bmatrix} 2 & 3 \\ 3 & 5 \end{bmatrix}$$

共轭。

§ 3.6 共轭梯度法

对于二次函数

$$f(x) = \frac{1}{2} x^T A x + b^T x + c$$

若 $f(x)$ 可写成变量分离的形式, 即 $f(x) = f_1(x_1) + f_2(x_2) + \cdots + f_n(x_n)$ 则从任意一点出发, 只需分别沿每个坐标轴方向进行一维搜索, 就可得到 $f(x)$ 的最优解。

因此, 对于二次函数 $f(x)$, 只要我们能够找到一组基 $\{p_1, \dots, p_n\}$, 使 p_i 满足条件 $p_i^T A p_j = 0$ ($i \neq j$), 则在这组基下, 从任一点出发进行搜索, 可得最优解。

§ 3.6 共轭梯度法

如何构造两两A共轭的方向？

考虑在点 x^k 处，利用负梯度方向 $-\nabla f(x^k)$ 和前一个搜索方向 p_{k-1} 的组合构成 p_k ，使 p_k 与前 $k-1$ 个搜索方向 p_1, \dots, p_{k-1} 两两共轭。

对于

$$f(x) = \frac{1}{2} x^T A x + b^T x + c$$

有 $\nabla f(x) = Ax + b$

对于 $\forall x, y \in R^n$ ，有 $\nabla f(y) - \nabla f(x) = Q(y - x)$

从初始点为 x^1 和 $p_1 = -\nabla f(x^1)$ 出发，可得 $(x^2, p_2) \dots, (x^k, p_k)$ ，且有 p_1, \dots, p_k 相互共轭和 $x^{k+1} = x^k + \lambda_k p_k$ 。

§ 3.6 共轭梯度法

$$\frac{d f(x^k + \lambda p_k)}{d \lambda} = 0 \quad \leftarrow \text{求 } \lambda_k$$

即

$$\frac{d f(x^k + \lambda p_k)}{d \lambda} = p_k^T \nabla f(x^{k+1}) = 0$$

$$\Downarrow \quad \nabla f(x) = Ax + b$$

$$p_k^T [Ax^{k+1} + b] = 0$$

$$\Downarrow \quad x^{k+1} = x^k + \lambda_k p_k$$

$$p_k^T [A(x^k + \lambda_k p_k) + b] = 0$$

$$\Downarrow$$

$$p_k^T [\nabla f(x^k) + \lambda_k A p_k] = 0$$

$$\Downarrow$$

$$\lambda_k = -\frac{p_k^T \nabla f(x^k)}{p_k^T A p_k}$$

§ 3.6 共轭梯度法

对于 $\forall j \leq k$, 有

$$\frac{df(x^j + \lambda p_j)}{d\lambda} = p_j^T \nabla f(x^{j+1}) = 0$$

和

$$p_j^T \nabla f(x^{k+1}) = 0$$

又对于 $\forall j < k$, 根据 $\nabla f(y) - \nabla f(x) = A(y - x)$ 有

$$\nabla f(x^{k+1}) = \nabla f(x^{j+1}) + A(x^{k+1} - x^{j+1})$$

↓ 两边乘 p_j^T

$$0 = p_j^T \nabla f(x^{k+1}) = p_j^T \nabla f(x^{j+1}) + p_j^T A[(x^{k+1} - x^k) + (x^k - x^{k-1}) + \cdots + (x^{j+2} - x^{j+1})]$$

$$= 0 + p_j^T A\left(\sum_{i=j+1}^k \lambda_i p_i\right) = \sum_{i=j+1}^k \lambda_i (p_j^T A p_i) = 0$$

§ 3.6 共轭梯度法

另外, 令 $p_{k+1} = -\nabla f(x^{k+1}) + \alpha_k p_k$



两边乘 $p_k^T A$

$$p_k^T A p_{k+1} = p_k^T A (-\nabla f(x^{k+1})) + p_k^T A (\alpha_k p_k) = 0$$



$$\alpha_k = \frac{p_k^T A \nabla f(x^{k+1})}{p_k^T A p_k}$$

不难证明, 对于 $j \leq k-1$, 也有

$$p_j^T A p_{k+1} = 0$$

§ 3.6 共轭梯度法

由 $p_j^T \nabla f(x^{k+1}) = 0$, 有

$$\nabla^T f(x^{k+1}) p_j = 0$$

$$\Downarrow \quad p_j = -\nabla f(x^j) + \alpha_{j-1} p_{j-1}$$

$$\nabla^T f(x^{k+1}) [-\nabla f(x^j) + \alpha_{j-1} p_{j-1}] = 0$$

$$\Downarrow$$

$$-\nabla^T f(x^{k+1}) \nabla f(x^j) + \alpha_{j-1} \nabla^T f(x^{k+1}) p_{j-1} = 0$$

$$\Downarrow$$

$$0$$

$$\Downarrow$$

$$0$$

则有 $\nabla f^T(x^{k+1}) \nabla f(x^j) = 0, \quad j \leq k$

§ 3.6 共轭梯度法

$$f(x) = \frac{1}{2} x^T A x + b^T x + c$$

求解步骤：

1. 任选初始点 x^1 , $p_1 = -\nabla f(x^1)$, $k=1$.

2. 若 $\nabla f(x^k) = 0$, 则停止迭代；否则

$$x^{k+1} = x^k + \lambda_k p^k$$

$$\lambda_k = -\frac{p_k^T \nabla f(x^k)}{p_k^T A p_k}$$

$$p_{k+1} = -\nabla f(x^{k+1}) + \alpha_k p_k$$

$$\alpha_k = \frac{p_k^T A \nabla f(x^{k+1})}{p_k^T A p_k}$$

3. $k = k+1$, 返回2.

§ 3.6 共轭梯度法

对于一般二次可微函数，在每一点的局部，可进行二阶泰勒展开，因此，也可利用共轭梯度法进行求解。

这时，需要修改公式，使之不含A，则有

$$\begin{aligned}\alpha_k &= \frac{p_k^T A \nabla f(x^{k+1})}{p_k^T A p_k} = \frac{(A \lambda_k p_k)^T \nabla f(x^{k+1})}{(A \lambda_k p_k)^T p_k} & \dots x^{k+1} &= x^k + \lambda_k p_k \\ &= \frac{[A(x^{k+1} - x^k)]^T \nabla f(x^{k+1})}{[A(x^{k+1} - x^k)]^T p_k} & \nabla f(y) - \nabla f(x) &= A(y - x) \\ &= \frac{[\nabla f(x^{k+1}) - \nabla f(x^k)]^T \nabla f(x^{k+1})}{[\nabla f(x^{k+1}) - \nabla f(x^k)]^T p_k} & \nabla f^T(x^{k+1}) \nabla f(x^k) &= 0 \\ &= \frac{\|\nabla f(x^{k+1})\|^2}{\|\nabla f(x^k)\|^2} & p_{k+1} &= -\nabla f(x^{k+1}) + \alpha_k p_k \\ & & p_j^T \nabla f(x^{k+1}) &= 0\end{aligned}$$

§ 3.6 共轭梯度法

求解步骤：

1. 任选初始点 x^1 , $d^1 = -\nabla f(x^1)$, $k=1$.

2. 若 $\nabla f(x^k)=0$, 则停止迭代；否则

$$\lambda_k = \arg \min f(x^k + \lambda d^k)$$

$$x^{k+1} = x^k + \lambda_k d^k$$

$$d^{k+1} = -\nabla f(x^{k+1}) + \frac{\|\nabla f(x^{k+1})\|^2}{\|\nabla f(x^k)\|^2} d^k$$

3. $k = k+1$, 返回2.

§ 3.6 共轭梯度法

无约束最优化方法	搜索方向	步长	停止准则	特性
最速下降法	$d^k = -\nabla f(x^k)$	精确搜索求 λ_k	$\ \nabla f(x^k)\ < \varepsilon$	相邻两次迭代搜索方向正交
牛顿法	$d^k = -\nabla^2 f(x^k)^{-1} \nabla f(x^k)$	$\lambda_k = 1$	$\ \nabla f(x^k)\ < \varepsilon$	黑塞矩阵可逆，计算量大
修正牛顿法		精确搜索求 λ_k		
拟牛顿法 (变尺度法)	$d^k = -H_k \nabla f(x^k)$ $H_{k+1} = H_k + \frac{\delta_{k+1} \delta_{k+1}^T}{\delta_{k+1}^T \gamma_{k+1}} - \frac{H_k \gamma_{k+1} \gamma_{k+1}^T H_k}{\gamma_{k+1}^T H_k \gamma_{k+1}}$	精确搜索求 λ_k	$\nabla f(x^k) = 0$	只需一阶导数，不求逆
共轭梯度法	$d^{k+1} = -\nabla f(x^{k+1}) + \frac{\ \nabla f(x^{k+1})\ ^2}{\ \nabla f(x^k)\ ^2} d^k$	精确搜索求 λ_k	$\nabla f(x^k) = 0$	只需一阶导数

§ 3.6 共轭梯度法

例：求 $\min x_1^2 + 2x_2^2 - 2x_1x_2 + 2x_2 + 2$

取 $x^1 = (0, 0)^T$

解： $\nabla f(x) = (2x_1 - 2x_2, -2x_1 + 4x_2 + 2)^T$ ，

$k=1$ 时， $\nabla f(x^1) = (0, 2)^T \neq 0$ ， $d^1 = (0, -2)^T$ ， $f(x^1 + \lambda d^1) = 8\lambda^2 - 4\lambda + 2$

可得 $\lambda_1 = 1/4$ ，

$$x^2 = x^1 + \lambda_1 d^1 = \left(0, -\frac{1}{2}\right)^T, \quad \nabla f(x^2) = (1, 0)^T$$

$d^2 = (-1, -1/2)^T$

$k=2$ 时， $f(x^1 + \lambda d^1) = \lambda^2 + \frac{1}{2}(1 + \lambda)^2 - \lambda(1 + \lambda) - (1 + \lambda) + 2$

可得 $\lambda_2 = 1$ ，

$$x^3 = (-1, -1)^T, \quad \nabla f(x^3) = (0, 0)^T$$

故 $x^* = x^3 = (-1, -1)^T$ 为最优解。