

第四章 约束非线性规划

§ 4.1 最优性条件

本章主要研究如下优化模型：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, \dots, l \\ & g_i(x) \geq 0, \quad i = 1, \dots, m \\ & x \in R^n. \end{aligned}$$

其中可行域为

$$D = \{x \mid x \in R^n, h_j(x) = 0, g_i(x) \geq 0, j = 1, \dots, l, i = 1, \dots, m\}.$$

§ 4.1 最优性条件

设 $x' \in D$, 若有 $g_i(x') = 0$, 则称不等式约束 $g_i(x) \geq 0$ 为点 x' 处的起作用约束。且将下标集 $I = \{i \mid g_i(x') = 0, 1 \leq i \leq m\}$, 称为点 x' 的起作用下标集。

若有 $g_i(x') > 0$, 则称不等式约束 $g_i(x) \geq 0$ 为点 x' 处的不起作用约束。

显然, 等式约束 $h_j(x) = 0$ 都是起作用约束。

§ 4.1 最优性条件

只含不等式约束问题的最优性条件

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0 \\ & x \in R^n \end{aligned}$$

其中可行域

$$D = \{x \mid x \in R^n, g_i(x) \geq 0, i = 1, \dots, m\}.$$

设 x^* 是问题的极小点，则 x^* 可在可行域内或可行域的边界上。

(1) x^* 在可行域内部，约束不起作用，变为无约束问题， x^* 必满足 $\nabla f(x^*) = 0$.


(2) x^* 在可行域边界上，约束起作用。

§ 4.1 最优性条件

(i) 假设 x^* 位于一个约束条件的边界上, 即 x^* 只有一个起作用约束。不失一般性, 令 $g_1(x) \geq 0$ 为 x^* 的起作用约束, 故有 $g_1(x^*) = 0$ 。

若 x^* 是局部最优解, 则必有 $-\nabla f(x^*)$ 与 $\nabla g_1(x^*)$ 在同一直线上且方向相反, 则存在实数 $\gamma_1 \geq 0$, 使得

$$\nabla f(x^*) - \gamma_1 \nabla g_1(x^*) = 0$$




§ 4.1 最优性条件

(ii) 假设 x^* 位于两个约束条件的边界上, 即 x^* 有两个起作用约束, $g_1(x^*) = 0$, $g_2(x^*) = 0$ 。

此时, $\nabla f(x^*)$ 必位于 $\nabla g_1(x^*)$ 与 $\nabla g_2(x^*)$ 所形成的夹角内。

若 x^* 是局部最优解, 且 $\nabla g_1(x^*)$ 与 $\nabla g_2(x^*)$ 线性无关, 则 $\nabla f(x^*)$ 可由 $\nabla g_1(x^*)$ 与 $\nabla g_2(x^*)$ 的线性组合表示, 即存在实数 $\gamma_1, \gamma_2 \geq 0$, 使得

$$\nabla f(x^*) - \gamma_1 \nabla g_1(x^*) - \gamma_2 \nabla g_2(x^*) = 0$$



§ 4.1 最优性条件

推广到多个不等式约束，有

$$\begin{cases} \nabla f(x^*) - \sum_{i \in I} \gamma_i \nabla g_i(x^*) = 0 \\ \gamma_i \geq 0 \end{cases} \quad (*)$$

为了将不起作用约束也加入到上式中，增加一个条件：

$$\gamma_i g_i(x^*) = 0, i = 1, \dots, m.$$

则(*)式可改写为

$$\begin{cases} \nabla f(x^*) - \sum_{i=1}^m \gamma_i \nabla g_i(x^*) = 0 \\ \gamma_i g_i(x^*) = 0, i = 1, \dots, m. \\ \gamma_i \geq 0, i = 1, \dots, m. \end{cases}$$

§ 4.1 最优性条件

定理1 (不等式约束问题的最优性条件)

设 $x^* \in D$, f, g_i 在 x^* 处可微, 且 $\nabla g_i(x^*) (i \in I)$ 线性无关。

若 x^* 是局部最优解, 则存在 $\gamma^* = (\gamma_1^*, \gamma_2^*, \dots, \gamma_m^*)$

使得

$$\begin{cases} \nabla f(x^*) - \sum_{i=1}^m \gamma_i^* \nabla g_i(x^*) = 0 \\ \gamma_i^* g_i(x^*) = 0, i = 1, \dots, m. \\ \gamma_i^* \geq 0, i = 1, \dots, m. \\ g_i(x^*) \geq 0. \end{cases} \quad \leftarrow \text{KKT条件}$$

§ 4.1 最优性条件

➤ 只含等式约束问题的最优性条件

$$\begin{array}{ll}\min & f(x) \\ \text{s.t.} & h(x) = 0.\end{array}$$

设 x^* 是问题的极小点，在 x^* 处梯度 $\nabla f(x)$ 和 $\nabla h(x)$ 的方向必相同或相反，即存在 $\mu \neq 0$ ，使得

$$\nabla f(x^*) - \mu \nabla h(x^*) = 0$$

§ 4.1 最优性条件

定理2 (等式约束问题的最优性条件)

设 $x^* \in D$, $f, h_j (j=1, \dots, l)$ 在 x^* 的某一邻域内连续可微, 且 $\nabla h_j(x^*)$ 线性无关。若 x^* 是局部最优解, 则存在 $\mu^* = (\mu_1^*, \mu_2^*, \dots, \mu_l^*)$, 使得

$$\nabla f(x^*) - \sum_{j=1}^l \mu_j^* \nabla h_j(x^*) = 0$$



KKT条件

§ 4.1 最优性条件

➤ 同时含有等式和不等式约束问题的最优性条件

定理3 设 $x^* \in D$, f, g_i, h_j 在 x^* 处可微, 且 $\nabla g_i(x^*) (i \in I), \nabla h_j(x^*), j=1, \dots, l$ 线性无关。若 x^* 是局部最优解, 则存在 $\gamma^* = (\gamma_1^*, \gamma_2^*, \dots, \gamma_m^*)$ 和 $\mu^* = (\mu_1^*, \mu_2^*, \dots, \mu_l^*)$, 使得

$$\left\{ \begin{array}{l} \nabla f(x^*) - \sum_{i=1}^m \gamma_i^* \nabla g_i(x^*) - \sum_{j=1}^l \mu_j^* \nabla h_j(x^*) = 0 \\ \gamma_i^* g_i(x^*) = 0, i = 1, \dots, m. \\ \gamma_i^* \geq 0, i = 1, \dots, m. \\ g_i(x^*) \geq 0. \\ h_j(x^*) = 0. \end{array} \right.$$

← KKT条件
↓

最优解的一阶必要条件

满足KKT条件的可行点, 称为KKT点。

§ 4.1 最优性条件

例1 求下列非线性规划的KKT点

$$\begin{aligned} \max \quad & 14x_1 - x_1^2 + 6x_2 - x_2^2 + 7 \\ \text{s.t.} \quad & x_1 + x_2 \leq 2 \\ & x_1 + 2x_2 \leq 3 \end{aligned}$$

解：将非线性规划化为一般形式

$$\begin{aligned} \min \quad & f(x) = -14x_1 + x_1^2 - 6x_2 + x_2^2 - 7 \\ \text{s.t.} \quad & g_1(x) = -x_1 - x_2 + 2 \geq 0 \\ & g_2(x) = -x_1 - 2x_2 + 3 \geq 0 \end{aligned}$$

§ 4.1 最优性条件

设 $x^* = (x_1, x_2)^T$ 为 KKT 点, 则满足如下条件

$$\begin{cases} \nabla f(x^*) - \gamma_1 \nabla g_1(x^*) - \gamma_2 \nabla g_2(x^*) = 0 \\ \gamma_i g_i(x^*) = 0, i = 1, 2. \\ \gamma_i \geq 0, i = 1, 2. \\ g_i(x^*) \geq 0, i = 1, 2. \end{cases}$$

其中, $\nabla f(x^*) = (-14 + 2x_1, -6 + 2x_2)^T$ $\nabla g_1(x^*) = (-1, -1)^T$ $\nabla g_2(x^*) = (-1, -2)^T$

因此, 有

$$\begin{cases} -14 + 2x_1 + \gamma_1 + \gamma_2 = 0 \\ -6 + 2x_2 + \gamma_1 + 2\gamma_2 = 0 \\ \gamma_1(-x_1 - x_2 + 2) = 0 \\ \gamma_2(-x_1 - 2x_2 + 3) = 0 \\ \gamma_i \geq 0, i = 1, 2. \\ -x_1 - x_2 + 2 \geq 0 \\ -x_1 - 2x_2 + 3 \geq 0 \end{cases}$$

§ 4.1 最优性条件

(i) 两个约束条件均不起作用，则有 $\gamma_1 = \gamma_2 = 0$
代入KKT条件，有

$$\begin{cases} -14 + 2x_1 = 0 \\ -6 + 2x_2 = 0 \end{cases}$$

解得

$$\begin{cases} x_1 = 7 \\ x_2 = 3 \end{cases}$$

但该点不满足 $g_1(x^*) > 0$ 和 $g_2(x^*) > 0$ ，因此不是可行点。

§ 4.1 最优性条件

(ii) g_1 为起作用约束, g_2 为不起作用约束, 则有 $\gamma_2 = 0$
代入KKT条件, 有

$$\begin{cases} -14 + 2x_1 + \gamma_1 = 0 \\ -6 + 2x_2 + \gamma_1 = 0 \\ \gamma_1(-x_1 - x_2 + 2) = 0 \end{cases}$$

解得

$$\begin{cases} x_1 = 3 \\ x_2 = -1 \\ \gamma_1 = 8 \end{cases}$$

该点满足 $g_1(x^*) = 0$ 和 $g_2(x^*) > 0$, 因此 $x^* = (3, -1)^T$ 为KKT点。

§ 4.1 最优性条件

(iii) g_1 为不起作用约束, g_2 为起作用约束, 则有 $\gamma_1 = 0$
代入KKT条件, 有

$$\begin{cases} -14 + 2x_1 + \gamma_1 = 0 \\ -6 + 2x_2 + \gamma_1 = 0 \\ \gamma_2(-x_1 - 2x_2 + 3) = 0 \end{cases}$$

解得

$$\begin{cases} x_1 = 5 \\ x_2 = -1 \\ \gamma_1 = 4 \end{cases}$$

该点满足 $g_1(x^*) > 0$, 因此不是可行点。

§ 4.1 最优性条件

(iv) 两个约束条件均为起作用约束, 则有 $g_1(x^*) = 0, g_2(x^*) = 0$ 有

$$\begin{cases} -x_1 - x_2 + 2 = 0 \\ -x_1 - 2x_2 + 3 = 0 \end{cases}$$

解得

$$\begin{cases} x_1 = 1 \\ x_2 = 1 \end{cases}$$

代入KKT条件, 有

$$\begin{cases} -14 + 2 + \gamma_1 + \gamma_2 = 0 \\ -6 + 2 + \gamma_1 + 2\gamma_2 = 0 \end{cases} \longrightarrow \begin{cases} \gamma_1 = 20 \\ \gamma_2 = -8 \end{cases}$$

$\gamma_2 = -8 < 0$ 不满足条件, 因此该点不是可行点。

综上, 解得为KKT点为 $x^* = (3, -1)^T$, 且 $\gamma_1 = 8, \gamma_2 = 0$.

§ 4.1 最优性条件

例2 考虑非线性规划问题

$$\begin{aligned} \min \quad & (x_1 - 3)^2 + (x_2 - 2)^2 \\ \text{s.t.} \quad & x_1^2 + x_2^2 \leq 5 \\ & x_1 + 2x_2 = 4 \\ & x_1, x_2 \geq 0. \end{aligned}$$

检验 $x^* = (2, 1)^T$ 是否为KKT点。

解：将非线性规划写作一般形式

$$\begin{aligned} \min \quad & (x_1 - 3)^2 + (x_2 - 2)^2 \\ \text{s.t.} \quad & -x_1^2 - x_2^2 + 5 \geq 0 \\ & x_1 + 2x_2 - 4 = 0 \\ & x_1, x_2 \geq 0. \end{aligned}$$

§ 4.1 最优性条件

设 $x^* = (2, 1)^T$, KKT 条件如下:

$$\begin{cases} \nabla f(x^*) - \gamma_1 \nabla g_1(x^*) - \mu_1 \nabla h_1(x^*) = 0 \\ \gamma_1 g_1(x^*) = 0 \\ \gamma_1 \geq 0, i = 1, 2. \\ g_1(x^*) \geq 0 \\ h_1(x^*) = 0 \end{cases}$$

其中, $\nabla f(x) = (2x_1 - 6, 2x_2 - 4)^T$ $\nabla g_1(x) = (-2x_1, -2x_2)^T$ $\nabla h_1(x) = (1, 2)^T$

因此, 有

$$\begin{cases} 2x_1 - 6 + 2\gamma_1 x_1 - \mu_1 = 0 \\ 2x_2 - 4 + 2\gamma_1 x_2 - 2\mu_1 = 0 \\ \gamma_1(-x_1^2 - x_2^2 + 5) = 0 \\ \gamma_1 \geq 0 \\ -x_1^2 - x_2^2 + 5 \geq 0 \\ x_1 + 2x_2 - 4 = 0 \end{cases}$$

代入 x^*
→

$$\gamma_1 = 1/3 > 0 \quad \checkmark$$

$$\mu_1 = -2/3$$

$$g_1(x^*) = 0 \quad \checkmark$$

$$h_1(x^*) = 0 \quad \checkmark$$

因此, x^* 是 KKT 点。

§ 4.1 最优性条件

例3 给定非线性规划问题

$$\begin{aligned} \min \quad & f(x) = (x_1 - 1)^2 + x_2 \\ \text{s.t.} \quad & g_1(x) = -x_1 - x_2 + 2 \geq 0 \\ & g_2(x) = x_2 \geq 0 \end{aligned}$$

求满足KKT条件的点。

§ 4.2 可行方向法

求解带有约束条件的非线性规划问题的方法：

- 将非线性规划化为近似的线性规划（可行方向法）
- 将约束问题化为一个或一系列的无约束优化问题（惩罚函数法）
- 将复杂的问题变为较简单的问题（序列二次规划法）

§ 4.2 可行方向法

考虑非线性规划问题

$$\min f(x)$$

$$s.t. \quad Ax \geq b$$

$$Ex = e$$

约束为线性函数

其中, $f(x)$ 是可微函数, $A_{m \times n}$, $E_{l \times n}$, $x \in R^n$, $b \in R^m$, $e \in R^l$

$D = \{x \mid Ax \geq b, Ex = e\}$ --- 可行域

$$x^{k+1} = x^k + \lambda_k d^k \longrightarrow \text{下降方向} \quad f(x^{(k)} + \lambda_k d^{(k)}) < f(x^{(k)})$$

$$\text{可行方向} \quad x^k + \lambda_k d^k \in D$$

§ 4.2 可行方向法

下降方向:

设 $x \in R^n$, 若对于非零向量 d , 存在 $\delta > 0$, 使 $\forall \lambda \in (0, \delta)$ 均有 $f(x + \lambda d) < f(x)$, 则 d 为 f 在 x 处的下降方向。

可行方向:

设 D 为可行域, $x \in D$, 若对于非零向量 d , 存在 $\delta > 0$, 使得对 $\forall \lambda \in (0, \delta)$ 均有 $x + \lambda d \in D$, 则 d 为从 x 出发的可行方向。

可行方向法:

从可行点 x^k 出发, 寻找一下降的可行方向 d^k 作为搜索方向, 然后沿此方向确定移动步长, 得下一迭代点 x^{k+1} 。

§ 4.2 可行方向法

确定下降可行方向

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & Ax \geq b \\ & Ex = e \end{aligned} \quad (1)$$

在可行点 x^k 处, $A = [A_1, A_2]^T$, $b = [b_1, b_2]^T$,

且 $A_1 x^k > b_1$, $A_2 x^k = b_2$, $Ex^k = e$.

不起作用约束 起作用约束

令 $x = x^k + d$, 则 f 在 x^k 处的一阶泰勒展开为

$$f(x) \approx f(x^k) + \nabla f^T(x^k)d$$


则问题(1)变为

$$\min \quad f(x^k) + \nabla f^T(x^k)d$$

$$\text{s.t.} \quad A_1(x^k + d) \geq b_1$$

$$A_2(x^k + d) \geq b_2$$

$$E(x^k + d) = e$$



$$\min \quad \nabla f^T(x^k)d$$

$$\text{s.t.} \quad A_2 d \geq 0 \quad (2)$$

$$Ed = 0$$

§ 4.2 可行方向法

$$\begin{aligned} \min \quad & \nabla f^T(x^k)d \\ \text{s.t.} \quad & A_2 d \geq 0 \\ & Ed = 0 \end{aligned} \quad (2)$$

$d = 0$ 为问题(2)的可行点，且目标函数值为0，所以若 d^* 为最优解，则一定有 $\nabla f^T(x^k)d^* \leq 0$

当 $\nabla f^T(x^k)d^* < 0$ 时，则 d^* 为问题(1)在 x^k 处的下降可行方向。

当 $\nabla f^T(x^k)d^* = 0$ 时，则任意满足 $A_2 d \geq 0, Ed = 0$ 的 d 均有

$\nabla f^T(x^k)d \geq 0$ ，此时 d^* 为可行方向。

因此，可通过求解线性规划

$$\begin{aligned} \min \quad & \nabla f^T(x^k)d \\ \text{s.t.} \quad & A_2 d \geq 0 \\ & Ed = 0 \\ & -1 \leq d_i \leq 1 \end{aligned} \quad (3)$$

得到搜索方向(下降可行方向)。

§ 4.2 可行方向法

定理：设 x^k 是问题(1)的一个可行解, 且 $A_1x^k > b_1$, $A_2x^k = b_2$, 其中 $A = [A_1, A_2]^T$, $b = [b_1, b_2]^T$

则下来结论成立：

- 非零向量 d 是点 x^k 处的可行方向当且仅当 $A_2d \geq 0$, $Ed = 0$
- 若向量 d 又满足： $\nabla f^T(x^k)d < 0$, 则 d 是一个可行下降方向。

§ 4.2 可行方向法

确定步长

为使 $f(x^{k+1})$ 的值尽可能小，则 λ 越大越好，但需保证 $x^{k+1} \in D$ ，所以， $0 \leq \lambda \leq \lambda_{\max}$ 。

则通过求解一维搜索问题：

$$\min_{0 \leq \lambda \leq \lambda_{\max}} f(x^k + \lambda d^k) \quad (4)$$

得到步长 λ^k 。

§ 4.2 可行方向法

确定 λ_{\max}

$$\begin{aligned} \min \quad & f(x^k + \lambda d^k) \\ \text{s.t.} \quad & A(x^k + \lambda d^k) \geq b \\ & E(x^k + \lambda d^k) = e \end{aligned} \quad (5)$$

因 d^k 是可行方向, $Ed^k=0$. 又 x^k 为可行点, 有 $Ex^k=e$.

所以, 等式约束一定满足。

另外, 不等式约束可写成

$$A_1(x^k + \lambda d) \geq b_1 \quad (\text{i})$$

$$A_2(x^k + \lambda d) \geq b_2 \quad (\text{ii})$$

因 d^k 是可行方向, $A_2x^k = b_2$, $A_2d^k \geq 0$, $\lambda \geq 0$, 所以(ii)也成立。

§ 4.2 可行方向法

则(5)式可简化为

$$\begin{aligned} \min \quad & f(x^k + \lambda d^k) \\ \text{s.t.} \quad & A_1 x^k + \lambda A_1 d^k \geq b_1 \quad (\text{iii}) \\ & \lambda \geq 0 \end{aligned}$$

(iii)式可改写为 $\lambda A_1 d^k \geq b_1 - A_1 x^k$

\downarrow \downarrow $A_1 x^k > b_1$

v $u \ (u < 0)$

因此, 有 $\lambda v \geq u$

$$\lambda_{\max} = \begin{cases} \min \left\{ \frac{u_i}{v_i} \right\}, & v_i < 0 \\ \infty, & v_i \geq 0 \end{cases} \quad (6)$$

§ 4.2 可行方向法

可行方向法的求解步骤:

1. 选定初始点 x^0 , 精度 $\varepsilon > 0$, 令 $k = 0$.
2. 在点 x^k 处, 根据起作用约束和不起作用约束, 将 A 和 b 分别分解为 $A = [A_1, A_2]^T$, $b = [b_1, b_2]^T$, 使得 $A_1 x^k > b_1$, $A_2 x^k = b_2$.
3. 求解线性规划问题

$$\begin{aligned} \min \quad & \nabla f^T(x^k)d \\ \text{s.t.} \quad & A_2 d \geq 0 \\ & Ed = 0 \\ & -1 \leq d_i \leq 1 \end{aligned}$$

得到最优解 d^k .

4. 如果 $|\nabla f^T(x^k)d^k| < \varepsilon$, 则停止迭代, x^k 为所求最优点; 否则, 转5.

§ 4.2 可行方向法

5. 若 $A_1 d^k \geq 0$, 则从 x^k 出发, 沿 d^k 方向, 求 λ_k , 使 $f(x^k + \lambda_k d^k) = \min f(x^k + \lambda d^k)$. 令 $x^{k+1} = x^k + \lambda_k d^k$, 转7; 否则转6.

6. 令 $v = A_1 d^k$, $u = b_1 - A_1 x^k$, 计算 $\lambda_{\max} = \min \left\{ \frac{u_i}{v_i} \mid v_i < 0 \right\}$
求解 $\min_{0 \leq \lambda \leq \lambda_{\max}} f(x^k + \lambda d^k)$, 得到最优的 λ_k , 令 $x^{k+1} = x^k + \lambda_k d^k$, 转7.

7. 确定 x^{k+1} 的起作用约束, 修正 A_1, A_2 和 b_1, b_2 , 令 $k = k+1$, 返回2.

§ 4.2 可行方向法

例1：利用可行方向法求解：

$$\min f(x) = (x_1 - 6)^2 + (x_2 - 2)^2$$

$$s.t. \quad x_1 - 2x_2 \geq -4$$

$$-3x_1 - 2x_2 \geq -12$$

$$x_1 \geq 0$$

$$x_2 \geq 0$$

取 $x^0 = (2, 3)^T$, $\varepsilon = 0.001$

§ 4.2 可行方向法

解： x^0 代入约束条件 $g_1(x^0) = -4$

$$g_2(x^0) = -12$$

$$g_3(x^0) = 2 > 0$$

$$g_4(x^0) = 3 > 0$$

因此， $g_1(x)$ 和 $g_2(x)$ 为 x^0 处的起作用约束
故有

$$A_1 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad b_1 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

$$A_2 = \begin{bmatrix} 1 & -2 \\ -3 & -2 \end{bmatrix} \quad b_2 = \begin{bmatrix} -4 \\ -12 \end{bmatrix}$$

§ 4.2 可行方向法

确定搜索方向 $d^0 = (d_1, d_2)^T$

$$\nabla f(x) = [2(x_1 - 6), 2(x_2 - 2)]^T$$

$$\nabla f(x^0) = [-8, 2]^T$$

则线性规划为

$$\min -8d_1 + 2d_2$$

$$s.t. \quad d_1 - 2d_2 \geq 0$$

$$-3d_1 - 2d_2 \geq 0$$

$$-1 \leq d_1, d_2 \leq 1$$

解得 $d_1 = 2/3, d_2 = -1$

因 $|\nabla f^T(x^0)d^0| = \frac{22}{3} > \varepsilon$, 所以 x^0 不是最优解

§ 4.2 可行方向法

确定步长 λ_0

$$v = A_1 d^0 = \left(\frac{2}{3}, -1\right)^T \quad u = b_1 - A_1 x^0 = (-2, -3)^T$$

$$\text{则 } \lambda_{\max} = \min \left\{ \frac{-3}{-1} \right\} = 3$$

求解

$$\min_{0 \leq \lambda \leq 3} f(x^0 + \lambda d^0) = \frac{13}{9} \left(\lambda - \frac{33}{13} \right)^2 + \frac{100}{13}$$

解得 $\lambda_0 = 33/13$

故 $x^1 = x^0 + \lambda_0 d^0 = (48/13, 6/13)^T$

§ 4.2 可行方向法

进一步，将 x^1 代入约束条件

$$g_1(x^1) = 36/13 > -4$$

$$g_2(x^1) = -12$$

$$g_3(x^1) = 48/13 > 0$$

$$g_4(x^1) = 6/13 > 0$$

因此， $g_2(x)$ 为 x^1 处的起作用约束

故有

$$A_1 = \begin{bmatrix} 1 & -2 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} \quad b_1 = \begin{bmatrix} -4 \\ 0 \\ 0 \end{bmatrix}$$

$$A_2 = [-3 \quad -2] \quad b_2 = -12$$

§ 4.2 可行方向法

确定搜索方向 $d^1 = (d_1, d_2)^T$

$$\nabla f(x) = [2(x_1 - 6), 2(x_2 - 2)]^T$$

$$\nabla f(x^1) = \left[-\frac{60}{13}, -\frac{40}{13}\right]^T$$

则线性规划为

$$\begin{aligned} \min \quad & -\frac{60}{13}d_1 + \frac{40}{13}d_2 \\ \text{s.t.} \quad & -3d_1 - 2d_2 \geq 0 \\ & -1 \leq d_1, d_2 \leq 1 \end{aligned}$$

解得 $d_1 = 2/3, d_2 = -1$

因 $|\nabla f^T(x^1)d^1| = 0 < \varepsilon$, 所以 $x^1 = (48/13, 6/13)^T$ 为最优解。

§ 4.2 可行方向法

例2：考虑下列问题：

$$\min x_1^2 + x_1x_2 + 2x_2^2 - 6x_1 - 2x_2 - 12x_3$$

$$s.t. \quad -x_1 + 2x_2 \leq 3$$

$$x_1 + x_2 + x_3 = 2$$

$$x_1, x_2, x_3 \geq 0$$

求出在点 $x' = (1, 1, 0)^T$ 处的一个下降可行方向。

§ 4.2 可行方向法

解：先将问题化为

$$\begin{aligned} \min \quad & x_1^2 + x_1x_2 + 2x_2^2 - 6x_1 - 2x_2 - 12x_3 \\ \text{s.t.} \quad & x_1 - 2x_2 \geq -3 \\ & x_1 + x_2 + x_3 = 2 \\ & x_1, x_2, x_3 \geq 0 \end{aligned}$$

进一步，将 x' 代入约束条件

$$g_1(x') = -1 > -3$$

$$g_2(x') = 2$$

$$g_3(x') = 1 > 0$$

$$g_4(x') = 1 > 0$$

$$g_5(x') = 0$$

因此， $g_2(x)$ 和 $g_5(x)$ 为 x' 处的起作用约束。

§ 4.2 可行方向法

相应地，有

$$\begin{aligned} A_1 &= \begin{bmatrix} -1 & 2 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} & b_1 &= \begin{bmatrix} -3 \\ 0 \\ 0 \end{bmatrix} \\ A_2 &= [0 \quad 0 \quad 1] & b_2 &= 0 \end{aligned}$$

设 $d = (d_1, d_2, d_3)^T$ 为下降可行方向，其应满足如下条件：

$$\begin{cases} d_3 \geq 0 & (A_2 d \geq 0) \\ d_1 + d_2 + d_3 = 0 & (Ed = 0) \\ -3d_1 + 3d_2 - 12d_3 < 0 & (\nabla f^T(x')d < 0) \end{cases}$$

如 $d = (0, -1, 1)^T$ 满足以上条件。

§ 4.3 惩罚函数法

约束非线性规划的数学模型

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, \dots, l \\ & g_i(x) \geq 0, \quad i = 1, \dots, m \\ & x \in R^n. \end{aligned}$$

可行域 $D = \{x \mid x \in R^n, h_j(x) = 0, g_i(x) \geq 0, j = 1, \dots, l, i = 1, \dots, m\}$.

基本思想：根据约束的特点构造某种惩罚函数，使得对约束问题的求解，转换为一系列无约束问题的求解。

§ 4.3 惩罚函数法

(一) 外点法

基本思想：对违反约束的点在目标函数中进行相应的“惩罚”，而对可行点不予惩罚。

对于只含等式约束的问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, \dots, l \end{aligned}$$

定义惩罚函数为 $\varphi(x, \sigma) = f(x) + \sigma \sum_{j=1}^l h_j^2(x)$

$\sigma \geq 0$ 惩罚因子

惩罚项

§ 4.3 惩罚函数法

当 $x \notin D$, 即 $h_j(x) \neq 0$, 则有 $h_j^2(x) > 0$.

故若 $\sigma > 0$ (很大), 说明 $\varphi(x, \sigma)$ 的极小点不会是违反约束的 x .

因此, 将求解

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, \dots, l \end{aligned}$$

转化为对

$$\min_x \varphi(x, \sigma) = f(x) + \sigma \sum_{j=1}^l h_j^2(x)$$

的求解。

§ 4.3 惩罚函数法

对于只含不等式约束的问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0 \\ & x \in R^n \end{aligned}$$

当 $x \in D$, $g_i(x) \geq 0$, 希望惩罚项为0.

当 $x \notin D$, $g_i(x) < 0$, 希望惩罚项大于0.

构造惩罚项为 $\sigma [\max\{0, -g_i(x)\}]^2$

此时, 有 $\varphi(x, \sigma) = f(x) + \sigma \sum_{i=1}^m [\max\{0, -g_i(x)\}]^2$

且 $\varphi(x, \sigma) = \begin{cases} f(x), & x \in D \\ f(x) + \text{很大的正数}, & x \notin D \end{cases}$ 至少存在 i_1 , 使 $g_{i_1}(x) < 0$,
当 σ 很大 从而有罚项 $\geq \sigma [g_{i_1}(x)]^2$

§ 4.3 惩罚函数法

设原问题的最优解为 x^* , $\min_x \varphi(x, \sigma)$ 的最优解为 $x^*(\sigma)$

讨论 x^* 与 $x^*(\sigma)$ 的关系

(i) 若 $x^*(\sigma) \in D$, 则是原问题的最优解。

(ii) 若 $x^*(\sigma) \notin D$, 则 σ 充分大时, $x^*(\sigma)$ 会很靠近可行域的边界, 是原问题的近似最优解。

如何选取 σ , 使 $x^*(\sigma)$ 是所需的最优解?

通过迭代逐步增大 σ , 令 $\sigma_{k+1} = c\sigma_k$

$$c > 1, c = 5 \sim 10$$

§ 4.3 惩罚函数法

对于同时包含等式及不等式约束的问题

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, \dots, l \\ & g_i(x) \geq 0, \quad i = 1, \dots, m \end{aligned}$$

定义惩罚函数为

$$\varphi(x, \sigma) = f(x) + \sigma \sum_{i=1}^m [\max\{0, -g_i(x)\}]^2 + \sigma \sum_{j=1}^l h_j^2(x)$$

设原问题的最优解为 x^* , $\min_x \varphi(x, \sigma)$ 的最优解为 $x^*(\sigma)$

则有 $x^*(\sigma) \notin D \xrightarrow{\sigma \rightarrow +\infty} x^*$

解析法

§ 4.3 惩罚函数法

外点法的求解步骤:

1. 给定初始点 x^0 , 初始惩罚因子 σ_1 , 放大系数 $c > 1$, 精度要求 $\varepsilon > 0$, 令 $k=1$.

2. 以 x^{k-1} 为初始点, 令 $\sigma_k P(x) = \sigma_k \sum_{i=1}^m [\max\{0, -g_i(x)\}]^2 + \sigma_k \sum_{j=1}^l h_j^2(x)$
求解无约束问题

$$\min f(x) + \sigma_k P(x)$$

得到极小点 x^k .

3. 若 $\sigma_k P(x^k) < \varepsilon$, 则停止计算, 得到近似解 x^k ; 否则, 令 $\sigma_{k+1} = c\sigma_k$, $k = k+1$, 返回2.

§ 4.3 惩罚函数法

例：利用外点法求解下列问题：

$$\begin{aligned} \min f(x) &= (x_1 - 1)^2 + x_2^2 \\ s.t. \quad g(x) &= x_2 \geq 1. \end{aligned}$$

定义惩罚函数为

$$\begin{aligned} \varphi(x, \sigma) &= f(x) + \sigma \sum_{i=1}^m [\max\{0, -g_i(x)\}]^2 \\ &= (x_1 - 1)^2 + x_2^2 + \sigma [\max\{0, -(x_2 - 1)\}]^2 \\ &= \begin{cases} (x_1 - 1)^2 + x_2^2, & x_2 \geq 1 \\ (x_1 - 1)^2 + x_2^2 + \sigma(x_2 - 1)^2, & x_2 < 1 \end{cases} \end{aligned}$$

§ 4.3 惩罚函数法

利用解析法求解 $\min \varphi(x, \sigma)$ ，有

$$\frac{\partial \varphi}{\partial x_1} = 2(x_1 - 1) \quad \frac{\partial \varphi}{\partial x_2} = \begin{cases} 2x_2, & x_2 \geq 1 \\ 2x_2 + 2\sigma(x_2 - 1), & x_2 < 1 \end{cases}$$

令

$$\frac{\partial \varphi}{\partial x_1} = 0, \quad \frac{\partial \varphi}{\partial x_2} = 0$$

得到 $x^* = (1, 0)^T$ (舍)

$$x^* = \begin{bmatrix} 1 \\ \frac{\sigma}{1+\sigma} \end{bmatrix} \xrightarrow{\sigma \rightarrow \infty} \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

故 $x^* = (1, 1)^T$ 为问题的最优解。

§ 4.3 惩罚函数法

例2：利用外点法求解下列问题：

$$\begin{aligned} \min f(x) &= x_1^2 + x_2^2 \\ s.t. \quad h(x) &= x_1 + x_2 - 1 = 0. \end{aligned}$$

§ 4.3 惩罚函数法

(二) 内点法

基本思想：从可行域的内点出发，并在可行域内部进行搜索。因此，只适用于求解不等式约束问题。

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, i = 1, \dots, m. \end{aligned}$$

可行域为 $D = \{x \mid g_i(x) \geq 0, i = 1, \dots, m\}$.

当 $x \in D$ 内部， $g_i(x) > 0$ ，希望惩罚项很小.

当 $x \rightarrow D$ 边界，存在 $g_{i_1}(x) = 0$ ，希望惩罚项很大.

构造惩罚项为

$$rB(x) = r \sum_{i=1}^m \frac{1}{g_i(x)} \quad rB(x) = -r \sum_{i=1}^m \log g_i(x)$$

r ($r > 0$) 是一个很小的数

§ 4.3 惩罚函数法

此时，定义障碍函数

$$\varphi(x, r) = f(x) + rB(x)$$

且 $\varphi(x, r) = \begin{cases} f(x) + \text{有限的数}, & x \in D \text{ 内部} \\ +\infty, & x \rightarrow D \text{ 边界} \end{cases}$

希望障碍函数最优解 $x^*(r) \rightarrow$ 原问题最优解 x^*

在 D 的内部

在 D 的边界上

$$\varphi(x^*(r), r) = f(x^*(r)) - r \sum_{i=1}^m \log g_i(x^*(r)) \rightarrow f(x^*)$$

$$\sum_{i=1}^m \log g_i(x^*(r)) \rightarrow -\infty \quad \Rightarrow \quad r \rightarrow 0 \quad \downarrow \quad 0$$

$$rB(x) = r \sum_{i=1}^m \frac{1}{g_i(x)}$$

$$rB(x) = -r \sum_{i=1}^m \log g_i(x)$$

§ 4.3 惩罚函数法

设原问题的最优解为 x^* , $\min_{x \in D} \varphi(x, r)$ 的最优解为 $x^*(r)$

当 $r \rightarrow 0$, 则有 $x^*(r) \rightarrow x^*$

如何选取 r , 使 $x^*(r)$ 是所需的最优解?

通过迭代逐步减小 r , 令 $r_{k+1} = cr_k$

$$0 < c < 1$$

§ 4.3 惩罚函数法

内点法的计算步骤:

1. 给定初始点 $x^0 \in D$, 精度 $\varepsilon > 0$, 取 $r_1 > 0$, $0 < c < 1$, 令 $k = 1$.
2. 以 x^{k-1} 为初始点, 求 $\min_{x \in D} \varphi(x, r_k)$ 的最优解, 记为 x^k , 转3.
3. 若 $r_k B(x^k) < \varepsilon$, 则停止计算, 得到近似解 x^k ; 否则, 令 $r_{k+1} = cr_k$, $k = k+1$, 返回2.

§ 4.3 惩罚函数法

例：用内点法求解下列问题：

$$\min f(x) = \frac{1}{12}(x_1 + 1)^3 + x_2$$

$$s.t. \quad g_1(x) = x_1 - 1 \geq 0,$$

$$g_2(x) = x_2 \geq 0.$$

定义障碍函数为

$$\varphi(x, r) = \frac{1}{12}(x_1 + 1)^3 + x_2 + r\left(\frac{1}{x_1 - 1} + \frac{1}{x_2}\right)$$

利用解析法求解 $\min_{x \in D} \varphi(x, r_k)$ ，令

$$\frac{\partial \varphi}{\partial x_1} = \frac{1}{4}(x_1 + 1)^2 - \frac{r}{(x_1 - 1)^2} = 0$$

$$\frac{\partial \varphi}{\partial x_2} = 1 - \frac{r}{x_2^2} = 0$$

§ 4.3 惩罚函数法

解得

$$x^* = \begin{bmatrix} \sqrt{2\sqrt{r} + 1} \\ \sqrt{r} \end{bmatrix} \xrightarrow{r \rightarrow 0} \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

故 $x^* = (1, 0)^T$ 为问题的最优解。

§ 4.3 惩罚函数法

(三) 乘子法

考虑只有等式约束的情形：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, \dots, l. \end{aligned} \quad (1)$$

转化为

$$\min_x \varphi(x, \sigma) = f(x) + \sigma \sum_{j=1}^l h_j^2(x) \quad (2)$$

设 x^* 是问题(1)的最优解，那么 x^* 是否为问题(2)的最优解？

分析：若 x^* 是问题(2)的最优解，则有 $\nabla \varphi_x(x^*, \sigma) = 0$

而 $\nabla \varphi_x(x^*, \sigma) = \nabla f(x^*) + 2\sigma \sum_{j=1}^l \boxed{h_j(x^*)} \nabla h_j(x^*) = \nabla f(x^*) \neq 0$ **矛盾**

故 x^* 不是问题(2)的最优解。

§ 4.3 惩罚函数法

如何改进罚函数，使 x^* 也是其最优解？

$$\varphi(x, \sigma, \mu) = f(x) - \underbrace{\sum_{j=1}^l \mu_j h_j(x)}_{\text{乘子项}} + \underbrace{\frac{\sigma}{2} \sum_{j=1}^l h_j^2(x)}_{\text{惩罚项}} \quad (3)$$

若 x^* 是问题(1)的最优解，则 x^* 是问题(3)的最优解。

证明： x^* 是问题(1)的最优解，则有 $\nabla f(x^*) - \sum_{j=1}^l \mu_j \nabla h_j(x^*) = 0$

$$\text{而 } \nabla \varphi_x(x^*, \sigma, \mu) = \underbrace{\nabla f(x^*) - \sum_{j=1}^l \mu_j \nabla h_j(x^*)}_{\downarrow 0} + \sigma \sum_{j=1}^l \underbrace{h_j(x^*)}_{\downarrow 0} \nabla h_j(x^*) = 0$$

得证。

§ 4.3 惩罚函数法

如何确定 μ 和 σ ?

(i) 一般 σ 取充分大的数

(ii) 给定 $\sigma > 0$ 足够大, 已有 μ^k , 求解 $\min \varphi(x, \sigma, \mu^k)$ 得最优解 x^k

则有 $\nabla \varphi_x(x^k, \sigma, \mu^k) = \nabla f(x^k) - \sum_{j=1}^l \mu_j^k \nabla h_j(x^k) + \sigma \sum_{j=1}^l h_j(x^k) \nabla h_j(x^k) = 0$

$$\nabla f(x^k) - \sum_{j=1}^l (\mu_j^k - \sigma h_j(x^k)) \nabla h_j(x^k) = 0$$

又知 $\nabla f(x^*) - \sum_{j=1}^l \mu_j^* \nabla h_j(x^*) = 0$

故有 $\mu_j^{k+1} = \mu_j^k - \sigma h_j(x^k), j=1, \dots, l.$

接下来再求解 $\min \varphi(x, \sigma, \mu^{k+1})$, 可得到 x^{k+1} , 重复以上过程, 得到两个点列 $\{\mu^k\}, \{x^k\}$.

§ 4.3 惩罚函数法

乘子法的求解步骤：

1. 给定初始点 x^0 ，惩罚因子 σ ， $\mu^1 > 0$ ，精度 $\varepsilon > 0$ ， $c > 0$ ($c \in [2, 10]$)， $0 < \beta < 1$ ，令 $k = 1$.
2. 以 x^{k-1} 为初始点，求 $\min \varphi(x, \sigma, \mu^k)$ 的最优解，记为 x^k ,
3. 若 $\|h(x^k)\| < \varepsilon$ ，则停止计算，得到近似解 x^k ；否则，转4.
4. 若 $\frac{\|h(x^k)\|}{\|h(x^{k-1})\|} \geq \beta$ ，令 $\sigma = c\sigma$ ，转4；否则，直接转5.
5. 计算 $\mu_j^{k+1} = \mu_j^k - \sigma h_j(x^k)$ ，令 $k = k+1$ ，返回2.

§ 4.3 惩罚函数法

例：用乘子法求解下列问题：

$$\begin{aligned} \min f(x) &= 2x_1^2 + x_2^2 - 2x_1x_2 \\ \text{s.t. } h(x) &= x_1 + x_2 - 1 = 0. \end{aligned}$$

定义惩罚函数为

$$\varphi(x, \sigma, \mu) = 2x_1^2 + x_2^2 - 2x_1x_2 - \mu(x_1 + x_2 - 1) + \frac{\sigma}{2}(x_1 + x_2 - 1)^2$$

取 $\sigma = 2$ ，在第 k 次迭代，利用解析法求解 $\min \varphi(x, \sigma, \mu^k)$ ，有

$$\nabla \varphi_{x_1}(x, \sigma, \mu^k) = 4x_1 - 2x_2 - \mu^k + 2(x_1 + x_2 - 1) = 0$$

$$\nabla \varphi_{x_2}(x, \sigma, \mu^k) = 2x_2 - 2x_1 - \mu^k + 2(x_1 + x_2 - 1) = 0$$

则

$$x^k = \begin{bmatrix} \frac{\mu^k + 2}{6} \\ \frac{\mu^k + 2}{4} \end{bmatrix}$$

§ 4.3 惩罚函数法

因 $\mu^{k+1} = \mu^k - \sigma h(x^k)$

代入 $x^k = \begin{bmatrix} \frac{\mu^k + 2}{6} \\ \frac{\mu^k + 2}{4} \end{bmatrix}$, 有 $\mu^{k+1} = \frac{1}{6}\mu^k + \frac{1}{3}$

当 $k \rightarrow \infty$ 时, 有 $\mu^* = \frac{1}{6}\mu^* + \frac{1}{3} \rightarrow \mu^* = \frac{2}{5}$

则 $x^k = \begin{bmatrix} \frac{\mu^k + 2}{6} \\ \frac{\mu^k + 2}{4} \end{bmatrix} \xrightarrow{k \rightarrow \infty} \begin{bmatrix} \frac{2}{5} \\ \frac{3}{5} \end{bmatrix}$

§ 4.3 惩罚函数法

考虑只有不等式约束的情形：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) \geq 0, \quad i = 1, \dots, m. \end{aligned}$$

利用等式约束的结果，引入变量 y_i ，将上式化为等式约束

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & g_i(x) - y_i^2 = 0, \quad i = 1, \dots, m. \end{aligned}$$

则惩罚函数为

$$\begin{aligned} \tilde{\varphi}(x, y, \sigma, \mu) &= f(x) - \sum_{i=1}^m \mu_i (g_i(x) - y_i^2) + \frac{\sigma}{2} \sum_{i=1}^m (g_i(x) - y_i^2)^2 \\ \tilde{\varphi}(x, y, \sigma, \mu) &= f(x) + \sum_{i=1}^m \left\{ \frac{\sigma}{2} \left[y_i^2 - \frac{1}{\sigma} (\sigma g_i(x) - \mu_i) \right]^2 - \frac{\mu_i^2}{2\sigma} \right\} \end{aligned}$$

§ 4.3 惩罚函数法

$$\tilde{\varphi}(x, y, \sigma, \mu) = f(x) + \sum_{i=1}^m \left\{ \frac{\sigma}{2} \left[y_i^2 - \frac{1}{\sigma} (\sigma g_i(x) - \mu_i) \right]^2 - \frac{\mu_i^2}{2\sigma} \right\}$$

为使 $\tilde{\varphi}(x, y, \sigma, \mu)$ 取极小, 有

$$y_i^2 = \frac{1}{\sigma} [\max\{0, \sigma g_i(x) - \mu_i\}]^2$$

代入 y_i^2 , 因此, 有

$$\tilde{\varphi}(x, \sigma, \mu) = f(x) + \frac{1}{2\sigma} \sum_{i=1}^m \{[\max(0, \mu_i - \sigma g_i(x))]^2 - \mu_i^2\}$$

§ 4.3 惩罚函数法

对于同时含有等式及不等式约束的情形：

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, \dots, l \\ & g_i(x) \geq 0, \quad i = 1, \dots, m. \end{aligned}$$

可以定义惩罚函数为

$$\begin{aligned} \varphi(x, \sigma, \mu, \lambda) = & f(x) + \frac{1}{2\sigma} \sum_{i=1}^m \{[\max(0, \lambda_i - \sigma g_i(x))]^2 - \lambda_i^2\} \\ & - \sum_{j=1}^l \mu_j h_j(x) + \frac{\sigma}{2} \sum_{j=1}^l h_j^2(x) \end{aligned}$$

其中

$$\mu_j^{k+1} = \mu_j^k - \sigma h_j(x^k), \quad j = 1, \dots, l.$$

$$\lambda_i^{k+1} = \max(0, \lambda_i^k - \sigma g_i(x^k)), \quad i = 1, \dots, m.$$

§ 4.3 惩罚函数法

例：用乘子法求解下列问题：

$$\begin{aligned} \min \quad & x_1^2 + x_2^2 \\ \text{s.t.} \quad & x_1 \geq 1 \end{aligned}$$

定义惩罚函数为

$$\begin{aligned} \varphi(x, \sigma, \mu) &= f(x) + \frac{1}{2\sigma} \{[\max(0, \mu - \sigma g(x))]^2 - \mu^2\} \\ &= x_1^2 + x_2^2 + \frac{1}{2\sigma} \{[\max(0, \mu - \sigma(x_1 - 1))]^2 - \mu^2\} \\ &= \begin{cases} x_1^2 + x_2^2 - \frac{\mu^2}{2\sigma}, & x_1 - 1 \geq \frac{\mu}{\sigma} \\ x_1^2 + x_2^2 + \frac{1}{2\sigma} \{[\mu - \sigma(x_1 - 1)]^2 - \mu^2\}, & x_1 - 1 < \frac{\mu}{\sigma} \end{cases} \end{aligned}$$

§ 4.3 惩罚函数法

利用解析法求解 $\min \varphi(x, \sigma, \mu)$, 有

$$\nabla \varphi_{x_1}(x, \sigma, \mu) = \begin{cases} 2x_1, & x_1 - 1 \geq \frac{\mu}{\sigma} \\ 2x_1 - \mu + \sigma(x_1 - 1), & x_1 - 1 < \frac{\mu}{\sigma} \end{cases}$$

$$\nabla \varphi_{x_2}(x, \sigma, \mu) = 2x_2$$

在第 k 次迭代, 令 $\nabla \varphi_{x_1}(x, \sigma, \mu^k) = 0$, $\nabla \varphi_{x_2}(x, \sigma, \mu^k) = 0$

得到

$$x^k = \begin{bmatrix} \frac{\mu^k + \sigma}{2 + \sigma} \\ 0 \end{bmatrix}$$

§ 4.3 惩罚函数法

因 $\mu^{k+1} = \max(0, \mu^k - \sigma g(x^k)) = \mu^k - \sigma g(x^k)$

代入 $x^k = \begin{bmatrix} \frac{\mu^k + \sigma}{2 + \sigma} \\ 0 \end{bmatrix}$, 有 $\mu^{k+1} = \frac{2\mu^k + 2\sigma}{2 + \sigma}$

当 $k \rightarrow \infty$ 时, 有 $\mu^* = \frac{2\mu^* + 2\sigma}{2 + \sigma} \rightarrow \mu^* = 2$

则 $x^k = \begin{bmatrix} \frac{\mu^k + \sigma}{2 + \sigma} \\ 0 \end{bmatrix} \xrightarrow{k \rightarrow \infty} \begin{bmatrix} 1 \\ 0 \end{bmatrix}$

故 $x^* = (1, 0)^T$ 为问题的最优解。

§ 4.3 惩罚函数法

外点法：初始点可在 R^n 空间中任意选取。

惩罚因子很大时，求解惩罚函数相对困难，且迭代的中间结果往往不是可行解，不能作为原问题的近似最优解。

内点法：初始点是可行域的内点，难以选取。

迭代在可行域内部进行，中间的迭代结果可作为近似解。

乘子法：无需惩罚因子 $\sigma \rightarrow \infty$

惩罚函数的极小点为原问题的最优解。

§ 4.4 序列二次规划法

$$\begin{aligned} \min \quad & f(x) \\ \text{s.t.} \quad & h_j(x) = 0, \quad j = 1, \dots, l \\ & g_i(x) \geq 0, \quad i = 1, \dots, m \\ & x \in R^n. \end{aligned}$$

其中, f, g_i, h_j 均为实值连续函数, 具有二阶连续偏导数。

基本思想: 在迭代点 x^k 处, 用二次规划模型来替代约束非线性规划问题, 通过求解一系列二次规划的解来逼近原问题的解。

§ 4.4 序列二次规划法

计算步骤：

1. 给定初始点 x^0 , 精度 $\varepsilon > 0$, 令 $k=0$.
2. 求在点 x^k 处二次规划模型的最优解, 记为 d^k , 转3.
3. 若 $\|d^k\| < \varepsilon$, 则停止计算, 得到近似解 x^k ; 否则, 令 $x^{k+1} = x^k + d^k$, $k = k+1$, 返回2.

§ 4.4 序列二次规划法

$$\min f(x)$$

$$s.t. \quad h_j(x) = 0, \quad j = 1, \dots, l$$

$$g_i(x) \geq 0, \quad i = 1, \dots, m$$

$$x \in R^n.$$

如何将原问题化为二次规划模型？

二次规划：目标函数为二次实函数，约束为线性函数。

令 $x = x^k + d$ ，那么，在点 x^k 处的二次规划模型为：

$$\min \quad \frac{1}{2} d^T Q_k d + \nabla f^T(x^k) d$$

..... $f(x)$ 的二阶泰勒展开

$$s.t. \quad \nabla h_j^T(x^k) d + h_j(x^k) = 0, \quad j = 1, \dots, l$$

..... $h_j(x)$ 的一阶泰勒展开

$$\nabla g_i^T(x^k) d + g_i(x^k) \geq 0, \quad i = 1, \dots, m.$$

..... $g_i(x)$ 的一阶泰勒展开

一般 Q_k 为 $f(x)$ 在点 x^k 处的海塞矩阵

§ 4.4 序列二次规划法

例：考虑非线性规划

$$\begin{aligned} \min \quad & (x_1 - 2)^2 + x_2^2 \\ \text{s.t.} \quad & (x_1 - 1)^2 + (x_2 - 1)^2 - 1 \geq 0 \\ & x_1, x_2 \geq 0 \end{aligned}$$

取 $x^0 = (0, 0)^T$, 列出其在 x^0 处的二次规划模型.

$$\begin{aligned} \text{解：令 } f(x) &= (x_1 - 2)^2 + x_2^2 & g_1(x) &= (x_1 - 1)^2 + (x_2 - 1)^2 - 1 \\ g_2(x) &= x_1 & g_3(x) &= x_2 \end{aligned}$$

$$\nabla f(x) = (2x_1 - 4, 2x_2)^T \quad \nabla f(x^0) = (-4, 0)^T \quad \nabla^2 f(x) = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

$$\nabla g_1(x) = (2x_1 - 2, 2x_2 - 2)^T \quad \nabla g_1(x^0) = (-2, -2)^T$$

$$\nabla g_2(x) = (1, 0)^T \quad \nabla g_3(x) = (0, 1)^T$$

§ 4.4 序列二次规划法

设 $d = (d_1, d_2)^T$, 令 $x = x^0 + d$, 那么, 在点 x^0 处的二次规划模型为:

$$\begin{aligned} \min \quad & \frac{1}{2}(d_1, d_2) \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} d_1 \\ d_2 \end{pmatrix} + (-4 \quad 0) \begin{pmatrix} d_1 \\ d_2 \end{pmatrix} \\ \text{s.t.} \quad & (-2, -2) \begin{pmatrix} d_1 \\ d_2 \end{pmatrix} + 1 \geq 0 \\ & d_1, d_2 \geq 0 \end{aligned}$$

即

$$\begin{aligned} \min \quad & d_1^2 + d_2^2 - 4d_1 \\ \text{s.t.} \quad & -2d_1 - 2d_2 + 1 \geq 0 \\ & d_1, d_2 \geq 0 \end{aligned}$$

§ 4.4 序列二次规划法

如何求解二次规划问题？

考虑等式约束二次规划问题---Lagrange方法

$$\begin{aligned} \min \quad & \frac{1}{2} x^T Q x + c^T x \\ \text{s.t.} \quad & A^T x = b \end{aligned}$$


定义Lagrange函数

$$L(x, \mu) = \frac{1}{2} x^T Q x + c^T x - \mu^T (A^T x - b)$$

根据一阶必要条件，有

$$\frac{\partial L(x, \mu)}{\partial x} = Qx + c - A\mu = 0$$

$$\frac{\partial L(x, \mu)}{\partial \mu} = -A^T x + b = 0$$



$$\begin{bmatrix} Q & -A \\ -A^T & 0 \end{bmatrix} \begin{bmatrix} x \\ \mu \end{bmatrix} = \begin{bmatrix} -c \\ -b \end{bmatrix}$$

§ 4.4 序列二次规划法

若 $\begin{bmatrix} Q & -A \\ -A^T & 0 \end{bmatrix}$ 可逆，可直接求解得到最优解 x^* 和最优的

Lagrange 乘子 μ^* 。

因一阶必要条件，也是KKT条件，所以在计算中也可直接求解方程组得到最优解。

§ 4.4 序列二次规划法

例：利用Lagrange方法求解下列问题

$$\begin{aligned} \min \quad & 2x_1^2 + x_2^2 + x_1x_2 - x_1 - x_2 \\ \text{s.t.} \quad & x_1 + x_2 = 1 \end{aligned}$$

解：定义Lagrange函数

$$L(x, \mu) = 2x_1^2 + x_2^2 + x_1x_2 - x_1 - x_2 - \mu^T(x_1 + x_2 - 1)$$

$$\frac{\partial L(x, \mu)}{\partial x_1} = 4x_1 + x_2 - 1 - \mu = 0$$

$$\frac{\partial L(x, \mu)}{\partial x_2} = x_1 + 2x_2 - 1 - \mu = 0$$

$$\frac{\partial L(x, \mu)}{\partial \mu} = -(x_1 + x_2 - 1) = 0$$

$$\rightarrow x^* = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \frac{1}{4} \\ \frac{3}{4} \end{bmatrix}$$

$$\mu^* = \frac{3}{4}$$

§ 4.4 序列二次规划法

考虑不等式约束二次规划问题---有效集方法

$$\begin{aligned} \min \quad & \frac{1}{2} x^T Q x + c^T x \\ \text{s.t.} \quad & a_i^T x \geq b_i, \quad i = 1, \dots, m. \end{aligned} \quad (1)$$

定义Lagrange函数

$$L(x, \mu) = \frac{1}{2} x^T Q x + c^T x - \sum_{i=1}^m \mu_i (a_i^T x - b_i)$$

设 x^* 为问题的最优解, 则必有

$$Qx^* + c - \sum_{i=1}^m \mu_i a_i = 0 \quad \longrightarrow \quad \text{计算} \mu_i$$

$$\mu_i \geq 0.$$

§ 4.4 序列二次规划法

设在迭代点 x 处的起作用约束集为 $W = \{i \mid a_i^T x = b_i\}$ ，则可通过求解等式约束二次规划问题

$$\begin{aligned} \min \quad & \frac{1}{2} x^T Q x + c^T x \\ \text{s.t.} \quad & a_i^T x = b_i, \quad i \in W. \end{aligned} \quad (2)$$

得到问题(1)的最优解。

当(2)的解是(1)的可行点，则还需判断相应的 μ_i 是否满足 $\mu_i \geq 0$ 。若满足，则停止计算；否则，去掉一个约束，重新求解新的等式约束二次规划问题。

如何增加或减少约束呢？

当(2)的解不是(1)的可行点，则需增加约束，然后求解所得到的等式约束二次规划问题。

§ 4.4 序列二次规划法

设第 k 次迭代点 x^k 处的起作用约束集为 W_k , 令 $x = x^k + d$

$$\begin{aligned} \text{有 } \frac{1}{2} x^T Q x + c^T x &= \frac{1}{2} (x^k + d)^T Q (x^k + d) + c^T (x^k + d) \\ &= \frac{1}{2} \underbrace{(x^k)^T Q x^k}_{\text{red}} + \underbrace{(x^k)^T Q d}_{\text{green}} + \frac{1}{2} d^T Q d + \underbrace{c^T x^k}_{\text{red}} + \underbrace{c^T d}_{\text{green}} \\ Qx^k + c &= \nabla f(x^k) \\ &= \frac{1}{2} d^T Q d + \nabla f^T(x^k) d + C \end{aligned}$$

$$\text{且 } a_i^T x = b_i \rightarrow a_i^T (x^k + d) = b_i \rightarrow a_i^T d = 0 \quad (i \in W_k)$$

故问题(2)可简化为问题(3)

$$\begin{aligned} \min \quad & \frac{1}{2} d^T Q d + \nabla f^T(x^k) d \\ \text{s.t.} \quad & a_i^T d = 0, \quad i \in W_k. \end{aligned} \quad (3)$$

§ 4.4 序列二次规划法

$$\begin{aligned} \min \quad & \frac{1}{2} d^T Q d + g^T d \\ \text{s.t.} \quad & a_i^T d = 0, \quad i \in W_k. \end{aligned} \quad (3)$$

根据问题(3), 若 x^k 不是最优解, 分析如何增加或减少约束来得到新的等式约束二次规划问题, 即确定 W_{k+1} .

设 d^k 为(3)的解, μ_i^k 为相应的乘子。

(i) 当 $d^k = 0$, 则 x^k 是问题(2)的最优解。若 $\mu_i^k \geq 0$, 则停止计算; 否则, 令 $\mu_j^k = \min\{\mu_i^k < 0, i \in W_k\}$, 则去掉 μ_j^k 所对应的约束, 有 $W_{k+1} = W_k \setminus j$

§ 4.4 序列二次规划法

(ii) 当 $d^k \neq 0$, 令 $x^{k+1} = x^k + \alpha_k d^k$, 使 $a_i^T (x^k + \alpha_k d^k) = b_i$ 成立。

若 $x^k + d^k$ 是可行点, 则令 $x^{k+1} = x^k + d^k$, 即 $\alpha_k = 1$ 。

若 $x^k + d^k$ 不是可行点, 则令 $x^{k+1} = x^k + \alpha_k d^k$, 需求解满足条件的 α_k 。

当 $i \in W_k$ 时, 满足约束, 即 $a_i^T (x^k + \alpha_k d^k) = b_i$ 总是成立的。

当 $i \notin W_k$ 时, 若 $a_i^T d^k \geq 0$, 则对所有的 $\alpha_k \geq 0$, 有 $a_i^T (x^k + \alpha_k d^k) \geq b_i$

若 $a_i^T d^k < 0$, 仅当 $\alpha_k \leq \frac{b_i - a_i^T x^k}{a_i^T d^k}$ 时, 有 $a_i^T (x^k + \alpha_k d^k) \geq b_i$

故取 $\alpha_k = \min \left\{ 1, \min \left\{ \frac{b_i - a_i^T x^k}{a_i^T d^k} \mid i \notin W_k, a_i^T d^k < 0 \right\} \right\}$

当 $\alpha_k < 1$ 时, 将 x^{k+1} 处的起作用约束 j , 加入到 W_k 中, 形成

$W_{k+1} = W_k \cup \{j\}$ 。

§ 4.4 序列二次规划法

有效集方法的计算步骤:

1. 给点初始可行点 x^0 , 令 x^0 处的起作用集为 W_0 , $k = 0$.
2. 求解问题(3), 得到 d^k .
3. 若 $d^k = 0$, 计算相应的 μ_i^k . 若 $\mu_i^k \geq 0$, 停止计算, 得到最优解 $x^* = x^k$; 否则, 确定 j_k , 令 $x^{k+1} = x^k$, $W_{k+1} = W_k \setminus \{j_k\}$, 转5.
4. 若 $d^k \neq 0$, 计算 α_k , 令 $x^{k+1} = x^k + \alpha_k d^k$. 若 $\alpha^k < 1$, 确定 x^{k+1} 处的起作用约束 j , 并加入到 W_k 中, 得到 $W_{k+1} = W_k \cup \{j\}$; 否则, 令 $W_{k+1} = W_k$.
5. 令 $k = k+1$, 转2.

§ 4.4 序列二次规划法

例：利用有效集方法求解下列问题：

$$\begin{aligned} \min \quad & (x_1 - 1)^2 + (x_2 - 2.5)^2 \\ \text{s.t.} \quad & x_1 - 2x_2 + 2 \geq 0 \\ & -x_1 - 2x_2 + 6 \geq 0 \\ & -x_1 + 2x_2 + 2 \geq 0 \\ & x_1, x_2 \geq 0 \end{aligned}$$